



**PERAMALAN JUMLAH KASUS POSITIF VIRUS COVID-19 SETELAH  
VAKSINASI DIBERLAKUKAN DI DKI JAKARTA DENGAN METODE  
ARIMA**

Tugas Akhir

Disusun sebagai salah satu syarat

Untuk memperoleh gelar Ahli Madya

Program Studi Statistika Terapan dan Komputasi

Oleh

Hanani Mustaghfiroh

4112318029

**JURUSAN MATEMATIKA  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
UNIVERSITAS NEGERI SEMARANG  
2021**

## **PERNYATAAN**

Dengan ini, saya

Nama : Hanani Mustaghfiroh

NIM : 4112318029

Program studi : Statistika Terapan dan Komputasi

menyatakan bahwa tugas akhir dengan judul peramalan jumlah kasus positif virus covid-19 di DKI Jakarta dengan metode arima ini benar – benar karya saya sendiri bukan jiplakan dari karya orang lain atau pengutipan dengan cara – cara yang tidak sesuai dengan etika keilmuan yang berlaku baik sebagian atau seluruhnya. Pendapat atau temuan orang lain atau pihak lain yang terdapat dalam tugas akhir ini telah dikutip atau dirujuk berdasarkan kode etik ilmiah . Atas pernyataan ini, saya secara pribadi siap mengganggu resiko/sanksi hukum yang dijatuhkan apabila ditemukan adanya pelanggaran terhadap etika keilmuan dalam karya ini.

Jakarta, Februari 2022

Hanani Mustaghfiroh

4112318029

## **PENGESAHAN**

Tugas Akhir berjudul *Peramalan Jumlah Kasus Positif Virus Covid-19 Setelah Vaksinasi Diberlakukan di DKI Jakarta dengan Metode Arima* karya Hanani Mustaghfiroh NIM 4112318029 ini telah dipertahankan dalam Ujian Tugas Akhir Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang pada Januari dan disahkan oleh  
Panitia Ujian:

Semarang, Februari 2022

### **Panitia**

Ketua,

Sekretaris,

Drs. Sugianto, M.Si

Drs. Mulyono

NIP. 196102191993031001

Nip 197009021997021001

Penguji I

Penguji II/Pembimbing

NIP.

NIP.196202071986011001

## **MOTTO**

- Teruslah berusaha sampai kamu mendapatkan apa yang kamu inginkan
- Tidak ada orang yang berhasil tanpa berusaha
- Kesabaran akan membawa kamu kepada kebahagiaan yang luar biasa
- Tuhan maha mendengar, maka perbanyaklah berdoa

## **PERSEMBAHAN**

Untuk ibu dan ayah yang selalu ada untuk ku

Dosen – dosen UNNES , dosen staterkom terutama

Sahabat dan teman

Teman – teman staterkom 2018

Teman – teman organisasi BEM FMIPA 2020,

Teman – teman citra kurnia kos

## PRAKATA

Segala puji dan syukur kehadiran Allah SWT yang telah melimpahkan rahmat serta hidayah-Nya, sehingga penulis dapat menyelesaikan tugas akhir dengan judul **“Peramalan Jumlah Kasus Positif Virus Covid-19 Setelah Vaksinasi Diberlakukan Di DKI Jakarta Dengan Metode Arima ”** yang disusun sebagai salah satu syarat untuk memperoleh gelar Ahli Madya pada Program Studi Statistika Terapan dan Komputasi, Fakultas Matematika dan Ilmu Pengetahuan Alam.

Menyadari bahwa terselesaikannya penulisan tugas akhir ini berkat bimbingan, arahan, bantuan dan dukungan dari berbagai pihak baik moril maupun materiel. Oleh karena itu pada kesempatan ini, penulis menyampaikan rasa hormat dan ungkapan terima kasih kepada:

1. Prof. Dr. Fathur Rokhman, M.Hum, Rektor Universitas Negeri Semarang,
2. Dr. Sugianto, M.Si., Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang,
3. Dr. Mulyono, M.Si., Ketua Jurusan Matematika FMIPA Universitas Negeri Semarang,
4. Dr. Iqbal Kharisudin, M.Sc., Ketua Program Studi Statistika Terapan dan Komputasi FMIPA Universitas Negeri Semarang,
5. Dr. Wardono, M.Si., Dosen pembimbing tugas akhir, yang telah memberikan bimbingan, arahan, saran dan koreksi sehingga tugas akhir ini dapat terselesaikan,
6. Bapak dan Ibu dosen Jurusan Matematika yang telah memberikan ilmu yang bermanfaat kepada penulis dalam penyusunan tugas akhir ini,
7. Ibu ,ayah, kakak tersayang dan keluarga yang selalu memberi motivasi, semangat dan doa dalam penyusunan tugas akhir ini,
8. Teman – teman staterkom 2018 yang sudah banyak membantu, memberi saran, memotivasi dan mendoakan dalam penyusunan tugas akhir ini,

9. Teman – teman sma yang membantu ku, memberikan dukungan dan doa dalam penyusunan tugas akhir ini,
10. Teman – teman kos yang selalu memotivasi dan mendoakan,
11. Teman-teman dan semua pihak lainnya, yang telah memberikan banyak bantuan dan motivasi dalam penyusunan tugas akhir

Penulis menyadari bahwa penyusunan tugas akhir ini masih jauh dari sempurna, sehingga dengan rendah hati penulis mengharap kritik dan saran. Penulis berharap semoga tugas akhir ini dapat berguna serta bermanfaat bagi para pembaca.

Jakarta, 13 Agustus 2021

Penulis

## ABSTRAK

Mustaghfiroh, Hanani (2021). *Peramalan Jumlah Kasus Positif Virus Covid-19 Setelah Vaksinasi Diberlakukan Di DKI Jakarta Dengan Metode Arima*. Tugas akhir, Statistika Terapan dan Komputasi Jurusan Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang. Pembimbing Dr. Wardono, M.Si

**Kata kunci :** Vaksinasi, Covid-19, Peramalan, Model *ARIMA Box Jenkins*

Pada bulan desember 2019, tepatnya di Wuhan, China, telah ditemukan penyakit baru yang dinamakan Covid-19 oleh *World Health Organization* (WHO). Wabah penyakit Covid-19 ini kemudian menyebar luas hingga ke seluruh dunia. Terkait hal ini, tentu pemerintah Indonesia melakukan banyak tindakan pencegahan penyebaran penyakit Covid-19. Salah satu tindakan yang dilakukan pemerintah Indonesia adalah mewajibkan untuk setiap orang yang tinggal di Indonesia untuk melakukan vaksinasi

Tujuan penelitian ini adalah untuk mengetahui hasil peramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta dengan metode arima . Metode pengumpulan data yang digunakan pada penelitian ini adalah metode dokumentasi

Berdasarkan hasil kegiatan analisis dan pembahasan peramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta diperoleh model peramalan yang cocok untuk data tersebut adalah ARIMA (2,1,2) dengan persamaan model  $1.0427X_{t-1} - 0.4839X_{t-2} + \omega_t - 1.5182\omega_{t-1} - 0.7861\omega_{t-2}$  dengan nilai RMSE 8,060256 dan AIC 1400,19

Dengan model tersebut didapatkan hasil bahwa jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta dapat diprediksi selama 12 periode kedepan, dengan hasil bahwa jumlah kasus positif virus covid-19 mengalami fluktuatif namun dominan menurun dari periode ke periode



## DAFTAR ISI

PERNYATAAN .....	i
PENGESAHAN .....	ii
ABSTRAK .....	iv
DAFTAR ISI .....	vi
DAFTAR TABEL.....	viii
DAFTAR GAMBAR .....	ix
BAB I .....	1
1.1    Latar Belakang.....	1
1.2    Rumusan Masalah.....	4
1.3    Pembatasan Masalah.....	5
1.4    Tujuan Penelitian .....	5
1.5    Manfaat Penelitian .....	5
1.6    Sistematika Penulisan Tugas Akhir .....	6
BAB II .....	8
2.1    Kasus Covid-19 : Asal Muasal, Gejala, Pencegahan .....	8
2.2    Gambaran umum Vaksin.....	8
2.3    Peramalan atau ( <i>forecasting</i> ).....	17
2.4    Runtun Waktu.....	19
2.5    Proses Stokastik.....	25
2.6    Proses Stasioner.....	27
2.7    Transformasi Runtun Waktu .....	28
2.8    Fungsi Autokorelasi (ACF).....	29
2.9    Fungsi Autokorelasi Parsial (PACF).....	30
2.10    Model Runtun Waktu.....	32
2.11    Estimasi.....	36
BAB III.....	39
3.1    Ruang Lingkup .....	39
3.2    Populasi dan Sampel Penelitian.....	39
3.3    Data Penelitian.....	40

3.4	Variabel Penelitian.....	40
3.5	Metode Pengumpulan Data .....	40
3.6	Analisis Data .....	41
BAB IV	.....	46
4.1	Hasil Penelitian.....	46
4.2	Pembahasan.....	56
BAB V	.....	58
5.1	Kesimpulan.....	58
5.2	Saran .....	59
DAFTAR PUSTAKA	.....	60
LAMPIRAN	.....	63

## DAFTAR TABEL

Tabel 2. 1 Keuntungan dan Kerugian Vaksin Inaktif .....	11
Tabel 2. 2 Keuntungan dan Kerugian Vaksin Dilemahkan.....	13
Tabel 2. 3 Keuntungan dan Kerugian Vaksin Subunit Rekombinan.....	14
Tabel 2. 4 Keuntungan dan Kerugian Vaksin Subunit Nonrekombinan .....	15
Tabel 3. 1 Plot Sampel ACF dan Pacf .....	41
Tabel 4. 1 Hasil Estimasi Model .....	52
Tabel 4. 2 Uji White Noise dan Uji Kolmogorv Smirnov .....	54
Tabel 4. 3 Data Hasil Peramalan Sebelum Diubah ke Data Asli .....	55
Tabel 4. 4 Data Asli Hasil Peramalan .....	57

## DAFTAR GAMBAR

Gambar 1. 1 Pola Data Jenis Horizontal .....	22
Gambar 1. 2 Pola Data Jenis Musiman .....	23
Gambar 1. 3 Pola Data Jenis Siklis .....	23
Gambar 1. 4 Pola Data Jenis Trend .....	23
Gambar 4. 1 Plot Grafik Data Asli Kasus Positif Covid-19 .....	46
Gambar 4. 2 Plot Grafik Data Kasus Positif Covid-19 Setelah Ditransformasi dan Differencing.....	48
Gambar 4. 3 Plot ACF dari Data Kasus Positif Covid 19 Setelah Differencing .....	49
Gambar 4. 4 Plot PACF dari Data Kasus Positif Covid 19 Setelah Differencing .....	49
Gambar 4. 5 Plot Data Peramalan Kasus Positif Covid-19.....	56



# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Pada tahun 2019, tepatnya pada bulan desember, dunia dihebohkan dengan adanya penyakit dari virus yang mewabah yang berasal dari kota Wuhan, China. Penyakit yang dikatakan baru pada waktu itu dinamakan penyakit Covid-19 oleh World Health Organization (WHO)(Ludwig & Zarbock, 2020). Pada tanggal 10 Januari 2020, penyakit ini diketahui termasuk dalam jenis virus *ribonucleid acid* (RNA) yaitu virus corona jenis baru, betacoronavirus dan masih termasuk kedalam jenis dari virus corona penyebab *Severe Acute Respiratory Syndrome* (SARS) dan *Middle East Respiratory Syndrome* (MERS Cov) (Handayani et al., 2020). Mula – mula pandemi ini hanya terjadi di Wuhan, China, kemudian menyebar luas ke daerah Amerika Utara dan Eropa , kemudian ke negara Brazil, Amerika Selatan. Dan akhirnya masuk ke daerah Asia seperti India , Irak dan Indonesia.

Sekitar tiga bulan kemudian setelah dikabarkan nya kasus pertama penyakit Covid-19 di China, tepatnya pada bulan maret, seseorang yang berasal dari kota Depok untuk pertama kali nya diberitakan menjadi orang pertama yang terkena virus Covid-19 di Indonesia. Dengan sigap kemudian pemerintah melakukan banyak tindakan untuk mencegah penyebaran virus Covid-19 lebih luas lagi (Rudianto et al., 2020). Hal – hal yang dilakukan oleh pemerintah untuk mencegah penyebaran virus Covid – 19 diantaranya adalah mewajibkan setiap orang untuk dirumah saja selama waktu yang ditentukan oleh pemerintah dan melakukan kegiatan – kegiatan yang biasa dilakukan seperti sekolah, kuliah bahkan kerja secara daring. Namun, hal itu tidak membuat kasus Covid-19 menurun melainkan dalam kurun waktu kurang dari sebulan setelah diberitakan

kasus pertama seseorang yang terkena virus Covid-19 di kota Depok tersebut sudah menyebar hingga keluar pulau Jawa

Tindakan lainnya yang dilakukan pemerintah Indonesia untuk pencegahan kasus Covid-19 adalah mewajibkan untuk setiap orang yang tinggal di Indonesia untuk melakukan vaksinasi. Tentunya seseorang yang akan divaksin harus memenuhi syarat untuk vaksinasi Covid-19. Karena tidak semua orang dapat divaksin. Seseorang yang memiliki riwayat penyakit tertentu yang sesuai syarat vaksinasi sajalah yang dapat diperbolehkan untuk melakukan vaksinasi Covid-19

Vaksin merupakan salah satu cara tindakan pencegahan penularan sebuah penyakit menular yang paling tepat, karena sifatnya efektif dan ekonomis. Maka sangat diperlukan untuk membuat pengembangan vaksin agar lebih efektif untuk melemahkan infeksi virus corona. Sejauh ini ada hampir dari 40 perusahaan farmasi dan lembaga akademis diseluruh dunia telah meluncurkan program pengembangan vaksin mereka untuk melawan infeksi *Sars-CoV-2* (Makmun & Hazhiyah, 2020). Program pemerintah untuk menjalani vaksinasi sangat membantu untuk pencegahan virus Covid-19 menyebar dan terlebih lagi selain dengan melakukan vaksinasi, harusnya diikuti dengan mematuhi protokol 3M (Menggunakan masker, Mencuci tangan dan Menjaga Jarak). Presiden Joko Widodo adalah salah satu orang yang mendapatkan dosis vaksin yang pertama. Kemudian diikuti oleh kelompok prioritas penerima vaksin Covid-19 , seperti para tenaga medis, pelayan public, TNI , Polri dan aparat hukum

Peramalan (*forecasting*) adalah suatu kegiatan yang bertujuan untuk memperkirakan sesuatu yang akan terjadi dimasa mendatang atau disebut juga sesuatu yang belum pernah terjadi. Peramalan adalah bagian dari cabang ilmu statistika yaitu inferensi . tetapi, dalam perkembangannya ilmu ini lebih sering diasosikan dengan cabang ilmu ekonometrika(Firdaus, 2004)

Menurut (Perdana, 2017) , peramalan dapat dilakukan dengan menggunakan dua metode, yaitu metode kualitatif dan metode kuantitatif. Metode kuantitatif melibatkan pengambilan data pada masa lampau dan memroyeksikan data tersebut pada masa mendatang dengan suatu bentuk model matematis dan biasanya metode ini biasa digunakan pada kondisi yang stabil. Metode kualitatif merupakan prediksi intuisi bersifat subjektif. Sementara metode kualitatif digunakan apabila data yang akan dievaluasi , terbatas dan cenderung berubah – ubah

Kemudian, pada metode kuantitatif dan metode kualitatif masih dibedakan lagi ke dalam beberapa model. Menurut (Makridakis et al., 1999), metode kualitatif dibedakan menjadi empat , yaitu Metode Delphi (*Delphi Method*), Juri dari opini eksekutif (*jury of executive opinion*), Komposit dari tenaga penjualan (*sales forces composite*), dan survei konsumen pasar (*customer market survey*)

Untuk melakukan peramalan nilai pada suatu variabel yang akan datang, perlu untuk memahami dan mempelajari terlebih dahulu sifat dan perkembangan variabel sebelumnya. Nilai dari suatu variabel dapat diramal jika sifat dari variabel tersebut diketahui di waktu sekarang dan di waktu lalu. Untuk mempelajari bagaimana perkembangan historis dari suatu variabel , biasanya urutan nilai – nilai variabel itu diamati menurut waktu. Urutan waktu tersebut dinamakan dengan runtun waktu yang dengan arti lain bahwa runtun waktu adalah serangkaian pengamatan terhadap suatu peristiwa, gejala, kejadian, atau variabel yang diambil dari waktu ke waktu, dicatat secara teliti menurut urutan – urutan waktu terjadinya dan kemudian disusun sebagai data. Sedangkan analisis runtun waktu adalah suatu metode kuantitatif untuk menentukan pola di mana data yang didapat merupakan kumpulan variabel – variabel yang diambil dari waktu ke waktu (Setiawan, 2013: 172)

ARIMA (*Autoregressive Integrated Moving Average*) merupakan penggabungan dari metode *moving average* dan metode *autoregressive* yakni



suatu metode peramalan data runtun waktu yang dimana memanfaatkan data historis dan data sekarang untuk menghasilkan peramalan jangka pendek yang akurat. Metode ARIMA merupakan metode yang fleksibel karena mengikuti pola data yang ada dan memiliki akurasi tinggi serta cenderung memiliki nilai error yang kecil karena prosesnya yang terperinci (Kolker, 2012)

Berdasarkan paparan diatas, peneliti ingin meramalkan berapa jumlah kasus positif Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta dengan melakukan simulasi menggunakan metode ARIMA (*Autoregressive Integrated Moving Average*) yang dimana metode ARIMA ini akan dapat digunakan untuk memprediksi perkembangan dari data virus Covid-19 yang pada kenyataannya perkembangan terkait kasus positif covid-19 mengalami perbedaan jumlah setiap harinya dan kapasitas nya sendiri semakin meningkat. Dalam penelitian ini data diambil mulai dari tanggal 17 Februari 2021 – 3 September 2021 dan dalam hal ini, maka peneliti memilih judul tugas akhir **“Peramalan Jumlah Kasus Positif Virus Covid-19 Setelah Vaksinasi Diberlakukan di DKI Jakarta Dengan Metode ARIMA ”**

## 1.2 Rumusan Masalah

Berdasarkan uraian latar belakang tersebut, maka secara garis besar masalah yang akan dikaji dalam tugas akhir ini sebagai berikut.

1. Bagaimana cara untuk merumuskan masalah peramalan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta?
2. Bagaimana penggunaan metode ARIMA untuk peramalan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta?
3. Berapa prediksi atau ramalan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta?

### **1.3 Pembatasan Masalah**

Agar penulisan dan pembahasan isi yang dilakukan lebih fokus pada inti dari permasalahan, maka dilakukan sebuah pembatasan masalah, penulisan tugas akhir ini dibatasi ,yaitu :

1. Membahas peramalan dengan menggunakan metode ARIMA untuk meramalkan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta
2. Landasan teori yang dibahas hanya akan berkaitan langsung dengan pokok perkara tugas akhir
3. Data yang diperoleh adalah data yang tersedia pada laman resmi riwayat file Covid-19 DKI Jakarta
4. Analisis dilakukan dengan menggunakan program aplikasi R

### **1.4 Tujuan Penelitian**

Tujuan yang ingin dicapai melalui penulisan tugas akhir ini selain untuk memenuhi syarat tugas akhir dalam program studi Statistika Terapan dan Komputasi Universitas Negeri Semarang adalah sebagai berikut.

1. Mengetahui cara menentukan rumusan masalah peramalan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta
2. Mengetahui penggunaan metode ARIMA untuk peramalan jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta
3. Mengetahui prediksi atau ramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta

### **1.5 Manfaat Penelitian**

Adapun manfaat tugas akhir ini adalah sebagai berikut.

**Bagi Mahasiswa**

1. Untuk memperdalam dan mengembangkan wawasan disiplin ilmu yang telah dipelajari dalam mengkaji permasalahan tentang metode ARIMA pada data runtun waktu
2. Menambah pengetahuan mahasiswa dalam menganalisis dan mengolah data dengan menggunakan program R, khusus nya dalam metode ARIMA

**Bagi Pembaca**

1. Sebagai referensi atau bahan bacaan bagi pembaca dan peneliti lainnya mengenai peramalan

**Bagi instansi**

1. Sebagai sumbangan pemikiran keilmuan Matematika, khususnya bidang peramalan
2. Dapat dijadikan sebagai bahan evaluasi pemerintah atau pihak yang ingin mengetahui prediksi penyebaran kasus covid di DKI Jakarta

## **1.6 Sistematika Penulisan Tugas Akhir**

Sistematika digunakan untuk mempermudah dalam memahami jalan pemikiran secara keseluruhan tugas akhir. Dalam hal ini secara garis besar penulisan tugas akhir ini dibagi dalam tiga bagian, yaitu.

### **1. Bagian awal**

Bagian awal tugas akhir ini meliputi halaman judul, halaman pernyataan, halaman pengesahan, halaman motto dan pembahasan , prakata , abstrak, daftar isi, daftar tabel , daftar gambar , dan daftar lampiran

### **2. Bagian isi**

Bagian isi tugas akhir terdiri atas lima bab, diantara nya yaitu

## BAB 1 PENDAHULUAN

Pada bab ini dipresentasikan latar belakang masalah, rumusan masalah, pembatasan masalah, tujuan penelitian, manfaat penelitian, dan sistematika penulisan tugas akhir

## BAB 2 LANDASAN TEORI

Pada bab ini dipresentasikan teori – teori yang menjadi kerangka berpikir untuk penyelesaian permasalahan dalam penelitian ini

## BAB 3 METODE PENELITIAN

Pada bab ini dipresentasikan populasi , sampel, variabel, definisi operasional, pengumpulan data, dan analisis data

## BAB 4 HASIL DAN PEMBAHASAN

Pada bab ini dipresentasikan terkait hasil penelitian dan pembahasan sebagai jawaban dari permasalahan

## BAB 5 PENUTUP

Pada bab ini dipresentasikan simpulan yang diperoleh dari hasil penelitian dan saran – saran yang diberikan peneliti berdasarkan simpulan yang diperoleh

### **3. Bagian akhir**

Bagian akhir berisi daftar pustaka dan lampiran – lampiran yang digunakan dalam penelitian

## **BAB II**

### **LANDASAN TEORI**

#### **2.1 Kasus Covid-19 : Asal Muasal, Gejala, Pencegahan**

Terciptanya kasus Covid-19 diyakini mula – mula dari hewan yang kemudian menyebar melalui manusia ke manusia penularan. Gejala utama Covid-19 seperti demam, batuk, pernapasan kesulitan, nyeri otot, dan kelelahan . Lebih parahnya , Covid-19 mengakibatkan pneumonia, pernapasan akut distres, sepsis, dan syok septik yang dapat menyebabkan kematian pasien. Seseorang dengan riwayat kesehatan yang cukup serius tampaknya lebih rentan terhadap penyakit seperti ini(CDC Goverment, 2019)

Berdasarkan fakta bahwa virus ditularkan di antara manusia, para ahli medis menyarankan agar seseorang memakai masker saat melakukan aktivitas sehari-hari, terutama di luar rumah yang di mana pasti akan ada beberapa bentuk interaksi. Ahli medis juga menganjurkan untuk menghindari kontak fisik dengan orang dengan gejala batuk , karena Infeksi mudah ditularkan dari orang yang sakit ke orang lain. Selain itu karena bukti menunjukkan bahwa infeksi yang berasal dari hewan, maka sebaiknya tidak mengunjungi tempat-tempat di mana banyak hewan seperti kebun binatang. Terlebih lagi medis juga mewajibkan semua orang untuk ikuti dan patuhi aturan umum; kebersihan tangan dan makanan;yaitu mencuci tangan secara menyeluruh dengan sabun dan air, menggunakan disinfektan berbasis alkohol dan pembersih, sebelum dan sesudah menggunakan barang tertentu atau makan serta setelah melakukan kontak dengan manusia dan hewan peliharaan

#### **2.2 Gambaran umum Vaksin**

Vaksin merupakan salah satu cara tindakan pencegahan penularan sebuah penyakit menular yang paling tepat, karena sifatnya efektif dan

ekonomis. Maka sangat diperlukan untuk membuat pengembangan vaksin agar lebih efektif untuk melemahkan infeksi virus corona. Sejauh ini ada hampir dari 40 perusahaan farmasi dan lembaga akademis diseluruh dunia telah meluncurkan program pengembangan vaksin mereka untuk melawan infeksi *Sars-CoV-2* (Makmun & Hazhiyah, 2020)

Proses pembuatan vaksin membutuhkan waktu dan penelitian yang sangat intensif. Berbagai biotek perusahaan sedang berkonsultasi terkait vaksin yang akan digunakan pada pandemic ini. Proses pembuatan vaksin ini memakan waktu selama berbulan-bulan. Vaksinasi dapat digunakan secara umum sesuai kebutuhan pengujian ekstensif untuk menentukan keamanan dan kemanjurannya (Bai Y et al., 2020)

Perlu untuk diketahui bahwa tidak semua individu bisa memenuhi syarat vaksinasi Covid-19, beberapa faktor diantaranya adalah usia, gangguan kekebalan tubuh, dan kondisi medis lain yang sudah ada sebelumnya. Menurut (Edwards & Hackell, 2020) mengklasifikasikan bahwa ada tiga kategori besar kekhawatiran orang tua di Amerika Serikat mengenai vaksin untuk anak: (1) kebutuhan vaksin yang dipertanyakan, (2) keamanan vaksin, dan (3) jaminan kebebasan memilih. Sementara itu, hasil survei (Trujillo & Motta, 2020) menunjukkan hanya sekitar 30% warga di Eropa yang siap menerima vaksin

Di Indonesia, vaksinasi telah dilakukan pada bulan februari Presiden Joko Widodo adalah salah satu orang yang mendapatkan dosis vaksin yang pertama. Kemudian diikuti oleh kelompok prioritas penerima vaksin Covid-19, seperti para tenaga medis, pelayan public, TNI, Polri dan aparat hukum

### **2.2.1 Jenis – Jenis Vaksin**

Pada umumnya, vaksin dikelompokkan menjadi dua jenis, yaitu vaksin terapeutik dan vaksin preventif. Vaksin terapeutik biasanya dipakai untuk pengobatan suatu penyakit seperti kanker. sedangkan vaksin preventif

digunakan untuk pencegahan suatu infeksi . Dengan diberikan nya vaksin ini kepada individu yang sehat dengan tujuan merangsang terbentuknya antibodi sebagai bentuk kekebalan tubuh dari suatu virus ataupun bakteri

Berikut adalah jenis – jenis vaksin.

### **1. Vaksin Inaktif (*Inactivated vaccine*)**

Vaksin ini berisikan distributor infeksi yang telah di inaktivasi atau telah dimatikan Vaksin inaktif atau vaksin yang telah dimatikan ini bersifat mampu merangsang pembentukan antibodi atau disebut juga immunogenik. Proses Inaktivasi virus dan bakteri dilakukan dengan cara memberikan reaksi kimia dimana patogen dibunuh menggunakan agen inaktivasi (*inactivating agent*) . Sifat vaksin inaktif , yaitu sebagai berikut.

- Vaksin tidak bisa bermutasi menjadi bentuk patogenik
- Vaksin tidak hidup, maka dari itu seluruh dosis antigen dimasukkan kedalam bentuk antigen
- Vaksin inaktif tidak dipengaruhi oleh circulating antibody
- Tidak dapat menimbulkan penyakit yang serupa
- Respon imun yang ditimbulkan sebagian besar adalah humoral
- Titer antibodi menurun selang beberapa waktu sehingga diperlukan dosis ulangan, dosis pertama hanya memacu dan menyiapkan sistem imun dan tidak menghasilkan imunitas protektif, respon imunprotektif baru akan terbentuk setelah dosis kedua dan ketiga

Contoh vaksin inaktif : Vaksin pertussis dari agen inaktif Glutaraldehyde (toksin pertussis) , vaksin rabies dari agen inaktif  $\beta$ -propiolaktone (virus rabies) , dan vaksin influenza serta vaksin polio

dari agen aniktif *formaldehyde* (digunakan pada proses inaktivasi virus influenza , polio, difteri dan toksin tetanus)

**Tabel 2. 1 Keuntungan dan Kerugian Vaksin Inaktif**

Keuntungan	Kerugian
Cenderung stabil dan aman	Mebutuhkan dosis yang berulang untuk mendapatkan imunitas jangka panjang
Teknologi produksi pembuatannya sederhana	Proses produksi harus dengan kultivasi
Resiko revesi (kembalinya virulensi mikroba rendah)	Hanya menimbulkan imunitas humoral
Mebutuhkan <i>adjuvant</i>	
Komponen vaksin yang menimbulkan respon imun tidak terdefinisi dengan baik	



## 2. Vaksin Dilemahkan (*Live-attenuated vaccine*)

Vaksin dilemahkan merupakan suatu vaksin yang terbuat dari mikroorganisme hidup. Vaksin ini menggunakan virus atau bakteri hidup namun dilemahkan di laboratorium. Virus yang berasal dari antigen yang dilemahkan ini tidak menyebabkan penyakit pada orang yang menerima vaksin, tetapi justru akan meningkatkan sistem kekebalan penerima vaksin untuk merespons sebanyak mungkin, terutama terhadap patogen berbahaya yang sebenarnya. Proses pelemahan patogen dapat dilakukan menggunakan beberapa cara seperti :

- Pasase berulang pada media / inang yang tidak semestinya
- Pasase dingin
- Genetic reassortment
- Teknologi DNA Rekombinan

Cara sederhana dilakukan dengan menumbuhkan patogen dalam kondisi yang tidak sesuai dengan habitatnya, sehingga terjadi adaptasi yang pada akhirnya dapat membuat patogen kesulitan memperbanyak diri di inang aslinya. Proses tersebut dinamakan pasase berulang. Pasase berulang dapat menggunakan inang berupa organ hewan seperti ginjal monyet ataupun ditumbuhkan pada suhu dingin 25°C. Pelemahan patogen untuk dipergunakan sebagai vaksin juga dapat menggunakan metode rekombinan misalnya dengan menghilangkan gen pengkode faktor virulensi tertentu menggunakan teknologi DNA rekombinan

Atenuasi dengan cara *genetic reassortment* biasanya terjadi pada patogen seperti virus dengan materi genetik yang bersegmen. Sebagai

contoh beberapa virus influenza yang memiliki materi genetik bersegmen dari beberapa strain ditumbuhkan dalam satu sel inang sehingga terjadi penyusunan ulang materi genetik yang akan menimbulkan virus dengan patogenitas yang lebih rendah

**Tabel 2. 2 Keuntungan dan Kerugian Vaksin Dilemahkan**

Keuntungan	Kerugian
Tidak perlu dosis berulang	Perlu adanya pemantauan intensif
Imunitas yang dihasilkan sampai jangka panjang	Adanya resiko reversi dan transmisi pathogen
Menghasilkan respon imun humoral dan imun seluler	Komponen vaksin yang menimbulkan respon imun tidak terdefinisi dengan baik

### 3. Vaksin Subunit Rekombinan

Vaksin subunit rekombinan merupakan vaksin yang dimana pada tahap produksinya menggunakan sebagian dari bagian mikroba yang dihasilkan melalui teknologi DNA Rekombinan. Gen yang mengkode antigen dari mikroba penyebab penyakit diisolasi dan disisipkan pada plasmid vektor yang kemudian diekspresikan menggunakan sel lain sebagai inang. Sebagai contoh vaksin subunit berupa VLP (*Virus Like Particle*) yang tersusun atas capsid dan protein permukaan virus yang dimana gen virus yang dibutuhkan diekspresikan dalam sel eukariot atau prokariot. Sistem ekspresi eukariot meliputi sel bakteri *E.coli*, *yeast*, dan *baculovirus* dan tidak memiliki materi genetik sehingga tidak dapat menimbulkan penyakit

**Tabel 2. 3 Keuntungan dan Kerugian Vaksin Subunit Rekombinan**

Keuntungan	Kerugian
Komposisi vaksin terdefinisi dengan baik	Memerlukan dosis berulang untuk mendapatkan imunitas jangka panjang
Aman digunakan	Membutuhkan adjuvant
Tidak banyak menimbulkan efek samping	Hanya menimbulkan imunitas humoral
Produksi dilakukan tanpa melalui tahapan kultivasi	

#### 4. Vaksin Subunit Nonrekombinan

Vaksin subunit non-rekombinan adalah vaksin yang dimana didapatkan dari bagian bakteri atau virus yang dihasilkan dengan melalui pengkulturan mikroba dan mengisolasi bagian tertentu dari mikroba tersebut. Sebagai contoh dari vaksin subunit nonrekombinan yang berupa toxoid/toxin yang telah dilemahkan yaitu vaksin tetanus. Toxin tetanus merupakan protein yang disekresikan dari bakteri *Clostridium tetanii*. Proses pembuatan vaksin tetanus dilakukan dengan menumbuhkan bakteri pada media dalam kondisi yang sesuai kemudian dilakukan isolasi toxin tetanus. Kemudian toxoid dimatikan dengan reagen kimia dan kemudian siap diinjeksikan sebagai vaksin. Hasil pembuatan bahan toksoid yang jadi disebut juga dengan *natural fluid plaid toxoid* yang dimana berfungsi untuk merangsang respon imun terhadap toksin tetanus. Imunisasi bakteri toksoid efektif digunakan selama satu tahun

**Tabel 2. 4 Keuntungan dan Kerugian Vaksin Subunit Nonrekombinan**

Keuntungan	Kerugian
Mebutuhkan adjuvant	Mebutuhkan dosis berulang untuk mendapat imunitas jangka panjang
Aman digunakan	Hanya menimbulkan imunitas humoral saja karena mikroba tidak dapat bereplikasi
Komposisi vaksin terdefinisi dengan baik	Proses produksi dengan kultivasi
Tidak banyak menimbulkan efek samping	

### **2.2.2 Manfaat Vaksin Covid-19**

Berikut ini merupakan manfaat dari diadakannya vaksinasi Covid-19 adalah sebagai berikut.

#### **1. Membentuk respons antibodi**

Kegunaan vaksin Covid-19 yang pertama yaitu membentuk respons antibodi untuk sistem kekebalan tubuh. Saat melakukan vaksinasi, sel B akan melekat pada permukaan virus Covid-19 yang sudah dimatikan lalu kemudian mencari fragmen yang cocok

#### **2. Pencegahan penyakit virus Covid-19**

Tercegahnya virus masuk kedalam tubuh apabila suatu individu telah di vaksinasi. Vaksinasi dilakukan dengan cara menyuntikkan vaksin ke dalam individu. Kemudian setelah disuntikan vaksin, maka vaksin Covid-19 tersebut akan merangsang sel tubuh manusia, terutama sel B yang memproduksi imunoglobulin. Hasil produksi imunoglobulin inilah yang mengakibatkan tubuh individu akan kebal pada penyakit *SARS-CoV-2* atau Covid-19

### **3. Mengahiri penyebaran virus Covid-19**

Menghentikan virus menyebar luas ke seluruh tubuh. Vaksin akan merangsang imun tubuh yang dihasilkan oleh sel B dan menghentikan virus Covid-19 masuk ke dalam tubuh

### **4. Menstimulasi terbentuknya herd immunity**

Suatu individu yang mendapatkan vaksin Covid-19 dapat melindungi orang-orang di sekitarnya, terutama orang – orang yang sangat berisiko, seperti lansia yang berusia di atas 70 tahun. Hal ini karena kemungkinan orang yang sudah divaksin untuk menularkan virus corona sangatlah kecil. Apabila vaksin Covid-19 diberikan secara massal, maka vaksin juga mampu mendorong terbentuknya kekebalan kelompok (*herd immunity*) dalam masyarakat. Hal ini berarti, orang yang belum bisa mendapatkan vaksin, misalnya bayi baru lahir, lansia, atau penderita kelainan sistem imun tertentu, bisa mendapatkan perlindungan dari orang-orang di sekitarnya. Kendati demikian, untuk mencapai herd immunity dalam suatu masyarakat, penelitian menyebutkan bahwa minimal 70 persen penduduk dalam negara tersebut harus sudah divaksin

### **5. Menurunkan angka kesakitan dan kematian akibat Covid-19**

Vaksin Covid-19 dapat memicu sistem imunitas tubuh untuk melawan virus corona. Dengan begitu, risiko Anda untuk terinfeksi virus ini akan jauh lebih kecil. Kalau pun seseorang yang sudah

divaksin tertular Covid-19, vaksin bisa mencegah terjadinya gejala yang berat dan komplikasi. Dengan begitu, jumlah orang yang sakit atau meninggal karena Covid-19 akan menurun

## **6. Meminimalkan dampak ekonomi dan social**

Manfaat vaksin Covid-19 tidak hanya untuk sektor kesehatan, tetapi juga sektor ekonomi dan sosial. Jika sebagian besar masyarakat sudah memiliki sistem kekebalan tubuh yang baik untuk melawan penyakit Covid-19, kegiatan sosial dan ekonomi masyarakat bisa kembali seperti semula

### **2.3 Peramalan atau (*forecasting*)**

Peramalan (*forecasting*) adalah suatu kegiatan yang bertujuan untuk memperkirakan sesuatu yang akan terjadi dimasa mendatang atau disebut juga sesuatu yang belum terjadi (Firdaus, 2004)

Menurut (Sudjana, 1989) peramalan adalah proses perkiraan (pengukuran) besarnya atau jumlah sesuatu pada waktu yang akan datang berdasarkan data pada masa lampau yang dianalisis secara ilmiah khususnya menggunakan metode statistika

Peramalan menjadi dasar untuk berbagai perencanaan dan proses pengambilan keputusan sehingga tak jarang peramalan disebut sebagai bagian integral dari kegiatan pengambilan keputusan (Makridakis et al., 1999)

Pada berbagai peristiwa yang terjadi dalam kehidupan sehari – hari , seringkali terdapat selang waktu antara kesadaran akan kebutuhan mendatang dengan peristiwa itu sendiri. Oleh karena itu, peramalan diperlukan untuk menetapkan kapan suatu peristiwa akan terjadi atau timbul sehingga Tindakan yang tepat dapat dilakukan

Fungsi peramalan atau forecasting terlihat pada saat pengambilan keputusan. Keputusan yang baik adalah keputusan yang didasarkan atas

pertimbangan apa yang akan terjadi pada waktu keputusan itu dilaksanakan. Apabila kurang tepat ramalan yang kita susun, maka masalah peramalan juga merupakan masalah yang selalu kita hadapi (Rosnani, n.d.)

Menurut (Heizer & Render, 2009), peramalan atau forecasting memiliki tujuan sebagai Untuk mengkaji kebijakan perusahaan yang berlaku saat ini dan dan di masa lalu serta melihat sejauh mana pengaruh di masa datang. Peramalan diperlukan karena adanya *time lag* atau delay antara saat suatu kebijakan perusahaan ditetapkan dengan saat implementasi. Peramalan merupakan dasar penyusutan bisnis pada suatu perusahaan sehingga dapat meningkatkan efektivitas suatu rencana bisnis

### **2.3.1 Jenis-jenis Peramalan (*Forecasting*)**

#### **1. Berdasarkan Jenis Data**

Berdasarkan jenis data ramalan yang disusun, peramalan dibagi menjadi dua jenis, yaitu (Saputro & Asri, 2000)

- a. Peramalan kualitatif, yaitu peramalan yang berdasarkan dari data kualitatif dimasa lampau. Hasil ramalan yang dibuat tergantung pada orang yang menyusunnya dikarenakan peramalan tersebut ditentukan berdasarkan pemikiran yang bersifat pendapat pribadi , intuisi, dan pengetahuan serta pengalaman dari penyusunnya. Umumnya peramalan secara kualitatif ini didasarkan atas hasil penyelidikan, seperti pendapat survei pengguna, pendapat para ahli dan survey konsumen
- b. Peramalan kuantitatif, yaitu peramalan yang berdasarkan atas data penjualan pada masa lalu. Hasil peramalan yang dibuat sangat tergantung pada metode yang dipergunakan dalam peramalan tersebut. Pada peramalan kuantitatif penggunaan

metode yang berbeda akan didapatkan hasil yang berbeda pula

## **2. Berdasarkan Sifat Penyusunannya**

Berdasarkan sifat penyusunannya, peramalan dibagi menjadi dua jenis, yaitu (Rosnani, 2007)

- a. Peramalan subjektif, yaitu peramalan yang didasarkan atas perasaan atau intuisi dari orang yang menyusunnya
- b. Peramalan objektif, yaitu peramalan yang didasarkan atas data yang relevan pada masa lalu, dengan menggunakan teknik-teknik dan metode-metode dalam penganalisaan data tersebut

## **3. Berdasarkan jangka waktunya**

- a. Peramalan jangka panjang  
Yaitu peramalan yang dilakukan untuk menyusun hasil ramalan yang jangka waktunya lebih dari satu setengah tahun
- b. Peramalan jangka pendek  
Yaitu peramalan yang dilakukan untuk menyusun hasil ramalan yang jangka waktunya kurang dari setengah tahun

## **2.4 Runtun Waktu**

Runtun Waktu adalah suatu rangkaian pengamatan  $x_t$ , yang dilakukan pada waktu  $t$ . Periode waktu  $t$  dapat berbentuk tahun, kuartal, bulan minggu dan dibeberapa kasus dapat juga hari atau jam. Sedangkan analisis runtun waktu adalah suatu metode kuantitatif untuk menentukan pola di mana data yang didapat merupakan kumpulan variabel – variabel yang diambil dari waktu ke waktu (Brockwell & Davis, 2002).



Untuk dapat memahami pemodelan runtun waktu, perlu diketahui beberapa jenis data menurut waktu , yang dapat dibedakan sebagai berikut :

1. Data *cross-section* adalah jenis data yang dikumpulkan untuk jumlah variable pada suatu titik waktu tertentu . model yang digunakan untuk memodelkan tipe ini adalah model regresi . Misalnya seperti dilakukan sebuah penelitian dimana populasi penelitian adalah air limbah pada bak inlet dan bak outlet RSUD Tanah Abang dan sampel penelitiannya adalah air limbah sebelum pengolahan dan air limbah sesudah pengolahan di RSUD Tanah Abang. Contoh lainnya: data kinerja perusahaan pada bulan agustus 2018 , terdiri dari data DER (*Debt to Equity Ratio*) , data ROE (*Return On Equity*) , NPM (*Net profit Margin*), dan data keuangan lainnya pada bulan agustus 2018
2. Data runtun waktu (*time series*) adalah jenis data yang dikumpulkan menurut urutan waktu dalam suatu rentang waktu tertentu untuk suatu kategori atau individu tertentu. Model yang digunakan untuk memodelkan tipe ini adalah model – model time series. Misalnya seperti data bulanan inflasi dari tahun 2015-2020, dan lain - lain
3. Data panel adalah jenis data yang dikumpulkan menurut urutan waktu dalam suatu rentang waktu tertentu pada sejumlah kategori. Model yang digunakan untuk memodelkan tipe ini adalah model data panel, model runtun waktu multivariat. Misalkan dimiliki data  $X$  = produksi sepatu per bulan dari 8 pabrik sepatu di Indonesia dalam 12 bulan terakhir. Maka, variabel  $X$  dapat digambarkan dengan notasi sebagai berikut.

**Tabel 2.5 Contoh Data Panel**

	PS1	PS2	...	PS8
Januari	$X_{1,1}$	$X_{1,2}$	...	$X_{1,8}$

Februari	$X_{2,1}$	$X_{2,2}$	...	$X_{2,8}$
$\vdots$	$\vdots$		...	$\vdots$
Desember	$X_{12,1}$	$X_{12,2}$	...	$X_{12,8}$

Pada contoh diatas, data produksi setiap pabrik sepatu (PS1 sampai PS8) dapat dipandang sebagai data runtun waktu (univariat), sedangkan data produksi pada setiap bulan tertentu (Januari sampai desember) merupakan data cross-section. Gabungan data *cross-section* dan data runtun waktu di atas merupakan data panel

Tujuan analisis runtun waktu adalah memahami dan menjelaskan mekanisme tertentu, meramalkan suatu nilai di masa depan, serta menoptimalkan sistem kendali. Analisis runtun waktu dapat diterapkan dalam bidang ekonomi, bisnis , industry, dan lain – lain (Makridakis et al., 1999)

#### **2.4.1 Komponen – Komponen**

Analisis data runtut waktu didasarkan pada asumsi bahwa data runtut waktu tersebut terdiri dari komponen - komponen Trend/kecenderungan (T), Siklus/cycle (C), Pola Musiman/Season (S), dan variasi acak/Random (R) yang akan menunjukan suatu pola tertentu. Penjelasan komponen – komponen tersebut adalah sebagai berikut.


1. Trend (T) merupakan sifat dari permintaan masa lalu terhadap waktu terjadinya apakah permintaan tersebut cenderung naik, turun atau konstan
2. Cycle (C) merupakan sifat dari permintaan dalam satu periode apakah mengalami permintaan dengan jumlah yang sama atau tidak

3. Season (S) merupakan Fluktuasi permintaan suatu produk yang dapat mengalami kenaikan atau penurunan pada saat saat musim tertentu. Pola ini biasanya disebabkan oleh factor cuaca, musim libur panjang, hari raya keagamaan yang akan berulang secara periodik tiap tahunnya
4. Random (R) merupakan permintaan suatu produk dapat berubah secara tiba- tiba yang disebabkan oleh faktor tertentu. Contoh bencana alam, promosi khusus, perusahaan pesaing, dimana faktor- faktor ini tidak dapat diperkirakan dan tidak mempunyai pola tertentu

#### **2.4.2 Jenis Pola Data Runtun Waktu**

Langkah penting dalam memilih suatu metode runtun waktu yang tepat adalah dengan mempertimbangkan jenis pola data, sehingga metode yang paling tepat dengan pola tersebut dapat diuji. Pola data dapat dibedakan menjadi empat jenis :


1. Pola horizontal, yaitu pola yang terjadi bilamana nilai data berfluktuasi di sekitar nilai rata – rata yang konstan . Misal penjualan suatu produk yang dimana pada penjualan tersebut nilai penjualannya tidak mengalami peningkatan atau penurunan dalam waktu tertentu



**Gambar 1. 1 Pola Data Jenis Horizontal**


2. Pola musiman, yaitu pola yang terjadi bilamana nilai data berfluktuasi di sekitar nilai rata – rata yang konstan . pada pola ini produk dicatat secara harian, bulan atau tahunan .Misal data penjualan makanan ringan, suplai suku cadang kendaraan bermotor, bahan bakar pemanas

ruang ,dan lain - lainnya




**Gambar 1. 2 Pola Data Jenis Musiman**

3. Pola siklis, yaitu pola yang terjadi bilamana datanya dipengaruhi oleh fluktuasi ekonomi jangka panjang seperti yang berhubungan dengan siklus bisnis . Misal penjualan produk seperti mobil, baja, dan peralatan utama lainnya



**Gambar 1. 3 Pola Data Jenis Siklis**

4. Pola trend, pola yang terjadi bilamana terdapat kenaikan atau penurunan sekuler jangka panjang dalam data . Misal penjualan banyak perusahaan, berbagai indikator bisnis atau ekonomi lainnya



**Gambar 1. 4 Pola Data Jenis Trend**

Salah satu metode yang menggunakan data runtun waktu adalah metode Autoregressive Integrated Moving Average (ARIMA) yang dimana metode ini

dikembangkan pada tahun 1970 oleh George E. P. Box dan Gwilym M. Jenkins, dua peneliti tersebut sekaligus mengenalkan analisis runtun waktu melalui bukunya yaitu *Time Series Analysis : Forecasting and Control*. Sejak saat itu, runtun waktu mulai banyak dikembangkan. Dasar perhitungan analisis runtun waktu adalah pengamatan saat ini ( $X_t$ ) tergantung pada 1 atau beberapa pengamatan sebelumnya ( $X_{t-k}$ ). Maka disimpulkan bahwa tujuan model ARIMA yaitu untuk menentukan hubungan statistic yang baik antar deret pengamatan yang diramal dengan nilai historis variabel tersebut sehingga peramalan dapat dilakukan dengan model tersebut

#### **2.4.3 Klasifikasi model runtun waktu**

Salah satu pengelompokkan model – model runtun waktu dapat diberikan sebagai berikut.

- a. Model stasioner, yakni suatu model yang sedemikian hingga semua sifat – sifat statistiknya tidak berubah dengan pergeseran waktu (yakni bersifat *time invariant*). Dalam aplikasi, sifat statistik yang sering menjadi perhatian adalah rata – rata (*expected value*), variansi (*variance*), serta ukuran keerataan antar data (*dependence*) yakni fungsi kovariansi (*covariance function*). Suatu model runtun waktu yang memenuhi sifat ketiga ukuran statistic ini bersifat *time-invariant* disebut sebagai proses *weekly*-stasioner. Pada model stasioner, sifat – sifat statistiknya dimasa yang akan datang dapat diramalkan berdasarkan data historis yang telah terjadi dimasa yang lalu. Beberapa model runtun waktu stasioner (khususnya sering disebut model linier dan homoskedastik) yang akan dibahas
- b. Model nonstasioner, model yang tidak memenuhi sifat model stasioner seperti masalah rata – rata (*expected value*), variansi (*variance*), serta

ukuran keerataan antar data (*dependence*) yakni fungsi kovariansi (*covariance function*)

Selain model yang telah dijelaskan diatas , banyak model runtun waktu ( stasioner dan nonstasioner) lain yang dikenal didalam literatur , sebagai contoh model siklus, model long memory(seperti model fractional ARIMA) , dan model – model lain, baik model linier maupun non linier . klasifikasi lain dari model runtun waktu dapat diberikan sebagai berikut.

- a. Model univariat. Pada model univariat hanya diamati suatu variabel runtun waktu
- b. Model multivariat (*multivariable*) . Pada model multivariat diamati lebih dari satu variabel runtun waktu

## 2.5 Proses Stokastik

Suatu proses stokastik, artinya  $X_t$  merupakan observasi yang tersusun melalui waktu mengikuti hukum probabilitas (Soejati, 1987). Proses stokastik adalah keluarga variabel random  $\{X_t, t \in T\}$  yang didefinisikan pada ruang probabilitas  $(\Omega, F, P)$

**Definisi 2.1.** Realisasi dari suatu proses stokastik

Fungsi  $\{X(w), w \in \Omega\}$  pada  $T$  disebut realisasi atau *sample-path* dari proses  $\{X_t, t \in T\}$

**Definisi 2.2.** Suatu runtun waktu (*time series*) adalah proses stokastik dimana  $T$  adalah himpunan waktu . Terminologi runtun waktu (*time series*) lebih mengacu kepada realisasi dari proses

Disini  $T$  secara umum menunjukkan suatu himpunan waktu. Jika  $T = \mathbb{R}$  atau  $\mathbb{R}^+$ , proses stokastik disebut runtun waktu kontinu (*continuous time series*). Jika  $T = \mathbb{Z}$  atau  $\mathbb{N}$ , proses stokastik disebut runtun waktu diskrit (*discrete time series*). Jika  $T = G$  adalah lokasi geografis, proses stokastik

disebut runtun waktu spasial (*spatial time series*) Sedangkan jika  $T = \{\mathbb{Z}, G\}$  dikenal istilah runtun waktu spasial-temporal (*space-time time series*)

**Definisi 2.3.** Fungsi Mean

$$m(t) = E(X_t) = \int_{-\infty}^{\infty} x dF_x(x, t), t \in T$$

Fungsi *mean* menyatakan nilai rata – rata (leverage) dari proses  $X_t$  pada keseluruhan waktu

**Definisi 2.4.** Fungsi Kovariansi

$$\gamma(t, s) = Cov(X_t X_s) = E \left( (X_t - m(t))(X_s - m(s)) \right), t, s \in T$$

**Definisi 2.5.** Fungsi Korelasi

$$\rho(t, s) = \frac{\gamma(t, s)}{\sqrt{\gamma(t, t)\gamma(s, s)}}$$

Sifat – sifat fungsi korelasi proses stokastik adalag sebagai berikut

1. Simetri :  $\gamma(t, s) = \gamma(s, t), \rho(t, s) = \rho(s, t), \forall t, s \in T$
2. *Positivity* :  $\gamma(t, t) \geq 0$  dan  $\rho(t, t) = 1, \forall t, s \in T$
3. Ketidaksamaan *Schwarz*

$$|\gamma(t, s)| \leq \sqrt{\gamma(t, t)\gamma(s, s)}$$

$$|\rho(t, s)| \leq 1, \forall t, s \in T$$

4. *Nonnegative definite*

$$\sum_{i=1}^n \sum_{j=1}^n x_i \gamma(t_i t_j) x_j \geq 0$$

$$\sum_{i=1}^n \sum_{j=1}^n x_i \rho(t_i t_j) x_j \geq 0$$

$$\forall t_i \in T, i = 1, 2, \dots, n, \forall x_i \in \mathbb{R}, i = 1, \dots, n \text{ dan } n \in \mathbb{N}$$

### Definisi 2.8 Fungsi Distributif Kumulatif

Misalkan  $T$  menyatakan himpunan dari semua vektor  $\{t = (t_1, t_2, t_3, \dots, t_n) \in T^n : t_1, t_2, t_3, \dots, t_n, n = 1, 2, 3 \dots\}$ . Maka CDF (dimensi berhingga) dari  $\{X_t, t \in T\}$  adalah fungsi  $\{F_t(o), t \in T\}$  didefinisikan pada  $t = (t_1, t_2, t_3, \dots, t_n)'$ ,  $x = (x_1, \dots, x_n) \in \mathbb{R}^n$  sebagai

$$\begin{aligned} F_x(x, t) &= F_x(x) = P(X_{t_1} \leq x_1, \dots, X_{t_n} \leq x_n) \\ &= F_{(x_1, x_2, x_3, \dots, x_n)}(x_1, \dots, x_n; t_1, \dots, t_n) \end{aligned}$$

### 2.6 Proses Stasioner

Suatu data runtun waktu yang stasioner harus memenuhi kriteria yaitu rata-rata, variansi, dan kovariansi pada setiap lag adalah tetap sama pada setiap waktu. Apabila runtun waktu tidak memenuhi kriteria tersebut maka data dikatakan tidak stasioner. Data runtun waktu dikatakan tidak stasioner jika rata-rata maupun variansinya tidak konstan, mengalami perubahan yang sistematis (Winarno, 2009)

#### 1. Stasioner dalam rata – rata

Stasioner dalam rata – rata (*mean*) berfungsi untuk menduga rata – rata dependen tanpa *realizations*. Model trend deterministic fungsi rata – rata dari proses ini dapat diwakili oleh kecendrungan waktu yang deterministik (Wei, 2006)

#### 2. Stasioner dalam Varian

Suatu data pengamatan dapat dinyatakan stasioner dalam variansi jika data tersebut memiliki nilai rata – rata yang relatif konstan, tidak tergantung pada waktu dan variansi dari fluktuasi tersebut

Dalam hal ini terdapat dua cara untuk mengecek kestasioneran data yaitu dengan *Box-Cox Transformation* dan *Differencing*. *Box-Cox* Hal ini jika



*differencing* ordo masih belum menghasilkan data yang stasioner, maka dapat dilakukan *differencing* ordo kedua, dan seterusnya hingga diperoleh data yang stasioner

## 2.7 Transformasi Runtun Waktu

Dalam analisis data runtun waktu, asumsi penting yang biasanya digunakan adalah stasioneritas data. Transformasi dilakukan apabila terjadi ketidak-stasioneran dalam varians sementara ketidak-stasioneran dalam mean biasanya ditandai dengan adanya suatu trend (Suhartono & Subanar, 2009)

### 1. Differencing

*Differencing* dilakukan agar data yang non-stasioner berubah menjadi stasioner. Operator *differencing backward-shift* dapat didefinisikan sebagai berikut.

$$BX_t = X_{t-1} \quad (2.1)$$

Keterangan :

$X_t$  = nilai variabel X pada waktu t

$X_{t-1}$  = nilai variabel X pada waktu t – 1

$B$  = *backward-shift*

dan dapat dikembangkan ke tingkatan yang lebih tinggi . contoh :

$$B^2X_t = B(BX_t) = X_t - 2X_{t-1} + X_{t-2}$$

Data yang belum stasioner harus dilakukan proses *differencing* hingga data menunjukkan kestasionerannya. Kestasioneran data dapat dilihat pada plot ACF dan plot PACF (Lestari & Wahyuningsih, 2012)

## 2. Transformasi Logaritma

Untuk menstabilkan variansi dari suatu data runtun waktu dapat digunakan transformasi Box-Cox. Transformasi Box-Cox merupakan salah satu jenis transformasi logaritma. Berikut ini merupakan definisi transformasi logaritma(Wei, 1994).

$$X_t' = \log(X_t) \quad (2.2)$$

Ada beberapa hal yang perlu diperhatikan dalam penggunaan transformasi logaritma ini yaitu :

1. Jika data asli menunjukkan sebaran nilai kurang dari 10 atau nilai mendekati nol, maka rumus transformasi logaritma yang digunakan adalah  $\log(X_t) + 1$
2. Jika data mengandung nilai nol , maka gunakan transformasi yang lain, misalnya seperti transformasi akar
3. Jika data banyak mendekati nol , maka semua data harus dikalikan 10 sebelum dijadikan ke logaritma

## 2.8 Fungsi Autokorelasi (ACF)

Autokorelasi adalah hubungan atau korelasi keeratan antar pengamatan dalam suatu data runtun waktu. Dan korelasi diantara  $X_t$  dan  $X_{t-k}$  dinyatakan sebagai berikut.

$$\rho_k = \frac{Cov(X_t, X_{t+k})}{\sqrt{Var(X_t)Var(X_{t+k})}} = \frac{[(X_t - \mu)(X_{t+k} - \mu)]}{\sqrt{(X_t - \mu)^2} \sqrt{(X_{t+k} - \mu)^2}} = \frac{\gamma_k}{\gamma_0} \quad (2.4)$$

Keterangan :

$$Var(X_t)Var(X_{t+k}) = \gamma_0$$

$$\mu = \text{rata - rata (mean)}$$

$\gamma_k$  = fungsi autokovarians pada lag  $-k$  untuk  $k = 1, 2, 3, \dots$

$\rho_k$  = fungsi autokorelasi pada lag  $-k$

$t$  = waktu pengamatan ( $t=1, 2, 3, \dots$ )

$X_t$  = pengamatan pada waktu ke  $t$

Pada keadaan stasioner fungsi autokovarians pada lag dan fungsi autokorelasi pada lag harus memenuhi (Wei, 1994)

1.  $\gamma_0 = \text{Var}(X_t)$ ;  $\rho_0 = 1$  untuk  $t = 1, 2, 3, \dots$
2.  $|\gamma_k| \leq \gamma_0$ ;  $|\rho_k| \leq 1$  untuk  $k = 1, 2, 3, \dots$
3.  $\gamma_k = \gamma_{-k}$  dan  $\rho_{-k}$  untuk semua  $k$

## 2.9 Fungsi Autokorelasi Parsial (PACF)

Fungsi Autokorelasi Parsial (PACF) pada lag  $-k$  merupakan korelasi dari di antara  $X_t$  dan  $X_{t+k}$  setelah dependensi linear antara  $X_t$  dan  $X_{t+k}$ . Variabel antara  $X_{t+1}, X_{t+2}, \dots, X_{t+k-1}$  dihiraukan. Kemudian dijabarkan bentuk PACF salah satunya sebagai berikut. Misalkan  $\{X_t\}$  adalah suatu proses stasioner yang dimana mean nya nol. Misalkan  $X_{t+k}$  dapat ditulis sebagai model linier

$$X_{t+k} = \alpha_{k1}X_{t+k} + \alpha_{k2}X_{t+k-2} + \dots + \alpha_{kk}X_t + e_{t+k}$$

dengan  $\alpha_{ki}$  merupakan parameter ke- $i$  dari persamaan regresi, dan  $e_{t+k}$  merupakan komponen *error* yang tidak berkorelasi dengan  $X_{t+k-j}$  untuk  $j \geq 1$ . Kalikan dengan  $X_{t+k-j}$  pada kedua sisi dan ambil nilai harapannya, maka diperoleh :

$$\begin{aligned} X_{t+k}X_{t+k-j} &= \alpha_{k1}X_{t+k}X_{t+k-j} + \alpha_{k2}X_{t+k-2}X_{t+k-j} + \dots \\ &\quad + \alpha_{kk}X_tX_{t+k-j} \end{aligned}$$

$$\begin{aligned} E(X_{t+k}X_{t+k-j}) &= E(\alpha_{k1}X_{t+k}X_{t+k-j} + E(\alpha_{k2}X_{t+k-2}X_{t+k-j}) + \dots \\ &\quad + E(\alpha_{kk}X_tX_{t+k-j})) \\ E(X_{t+k}X_{t+k-j}) &= \alpha_{k1}E(X_{t+k}X_{t+k-j}) + \alpha_{k2}E(X_{t+k-2}X_{t+k-j}) + \dots \\ &\quad + \alpha_{kk}E(X_tX_{t+k-j}) \\ COV(X_{t+k}X_{t+k-j}) &= \alpha_{k1}COV(X_{t+k}X_{t+k-j}) + \alpha_{k2}COV(X_{t+k-j}) + \dots \\ &\quad + \alpha_{kk}COV(X_tX_{t+k-j}) \\ \gamma(j) &= \alpha_{k1}\gamma(j-1) + \alpha_{k2}\gamma(j-2) + \dots + \alpha_{kk}\gamma(j-k) \end{aligned}$$

$$\alpha_k = \begin{bmatrix} \alpha_{k1} \\ \alpha_{k2} \\ \alpha_{k3} \\ \vdots \\ \alpha_{kk} \end{bmatrix}, \text{ dan } \rho_k = \begin{bmatrix} \rho(1) \\ \rho(2) \\ \rho(3) \\ \vdots \\ \rho(k) \end{bmatrix}$$

Menggunakan metode Cramer diperoleh nilai = nilai fungsi autokorelasi parsial  $\alpha_{kk}$  untuk lag  $k = 1, 2, \dots$

$$\alpha_{11} = \rho_1$$

$$\alpha_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$$

$$\alpha_{33} = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_2 \\ \rho_2 & \rho_1 & \rho_3 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}}$$

$$\vdots$$

$$\alpha_{kk} = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_2 & \dots & \rho_{k-2} & \rho_1 \\ \rho_1 & 1 & \rho_1 & \dots & \rho_{k-3} & \rho_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \dots & \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 & \dots & \rho_{k-2} & \rho_{k-1} \\ \rho_1 & 1 & \rho_1 & \dots & \rho_{k-3} & \rho_{k-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \dots & \rho_1 & 1 \end{vmatrix}}$$

## 2.10 Model Runtun Waktu

### 1. Proses White Noise

Suatu proses  $(X_t)$  disebut dengan Proses White Noise. Proses White Noise  $(X_t)$  adalah urutan barisan variabel random tidak terjadi korelasi dengan mean  $\mu$  yang sering diasumsikan bernilai 0 dan variansi  $\sigma^2$ , yaitu

$$\text{cov}(X_t, X_s) = \begin{cases} \sigma^2 & \text{Jika } t = s \\ 0 & \text{Jika } t \neq s \end{cases}$$

perhatikan dari pengertian di atas diperoleh bahwa :

$$\text{cov}(X_{t+h}, X_t) = \begin{cases} \sigma^2 & h = 0 \\ 0 & h \neq 0 \end{cases}$$

$$\text{cor}(X_{t+h}, X_t) = \begin{cases} 1 & h = 0 \\ 0 & h \neq 0 \end{cases}$$

dengan demikian proses White Noise bersifat stasioner . Proses ini merupakan *building-block* bagi proses stasioner lainnya. Sering ditulis  $X_t \sim W N(0, \sigma^2)$

## 2. Proses Model Autoregressive (AR)

Proses  $(X_t)$  adalah proses autoregressive orde  $p$  (AR(p)) didefinisikan dengan persamaan

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \omega_t, t \in Z \quad (2.5)$$

Keterangan :

$\phi_i$  = koefisien autoregresif

$i = 1, 2, 3, \dots, p$

$\omega_t$  = indeks dengan rata – rata nol dan varian  $\sigma^2$

$p$  = order AR

Didefinisikan operator lag (*backward-shift*) untuk proses  $\{X_t\}$  sebagai berikut.

$$(B^j X)_t = X_{t-j} \quad j, t \in Z$$

maka proses AR( $\rho$ ) dapat dituliskan sebagai berikut :

$$X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} - \dots - \phi_p X_{t-p} = \omega_t$$

$$X_t - \phi_1 (BX)_t - \phi_2 (B^2 X)_t - \dots - \phi_p (B^p X)_t = \omega_t$$

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) X_t = \omega_t$$

$$\phi_p(B) X_t = \omega_t$$

dengan polinomial  $\phi_p(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ . Jika polinomial  $\phi(B)$  memiliki sifat tertentu, maka proses AR(p) akan bersifat stasioner

### 3. Proses *Moving Average* (MA)

Proses Moving Average orde q, ( $X_t$ ), dapat dituliskan sebagai berikut.

$$\begin{aligned} X_t &= w_t + \theta_0 w_t + \theta_1 w_{t-1} + \dots + \theta_q w_{t-q} \\ &= \sum_{j=0}^q b_j w_{t-j}, w_t \sim W N(0, \sigma^2) \end{aligned} \quad (2.6)$$

dengan

$\theta_0 = 1, \theta_1, \theta_2, \dots, \theta_q$ . Pada model ini,  $E(\varepsilon_t) = \mu$  dapat diasumsikan bernilai 0. Apabila nilai  $\mu \neq 0$ , dapat ditunjukkan bahwa sifat stasioner dari proses MA(q) akan ekuivalen dengan analisis pada kasus  $\mu = 0$ , seperti yang akan dijelaskan di bawah ini

### 4. Model *Autoregressive Moving Average* (ARMA)

Suatu runtun waktu ( $X_t$ ) pada suatu proses *Autoregressive Moving Average* (ARMA(p,q)) dapat ditulis sebagai berikut.

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \omega_t + \theta_1 \omega_{t-1} + \dots + \theta_q \omega_{t-q} \quad (2.7)$$

dengan  $\phi_p \neq 0, \phi_q \neq 0$ , dan  $\sigma_\omega^2 > 0$ .

Catatan : Parameter p dan q secara berurutan disebut sebagai orde dari *autoregressive* dan *moving average*

dengan menggunakan operator *backshift*, proses ARMA(p,q) dapat ditulis menjadi

$$\phi(B)X_t = \theta(B)\omega_t \quad (2.8)$$

Model ARMA memiliki beberapa kasus , yaitu :

- Saat  $q = 0$ , model ini disebut model *autoregressive* dengan orde p, AR(p)
- Saat  $p = 0$  , model ini disebut model *moving average* dengan orde q, MA(q)

## 5. Model *Autoregressive Moving Integrated Average* (ARIMA)

Bentuk umum *Autoregressive Moving Average Integrated*

(ARIMA(p,d,q)) apabila ditulis menggunakan bentuk operator *backshift* akan seperti berikut.

$$\phi(B)(1 - B)^d X_t = \theta(B)\omega_t \quad (2.9)$$

dengan

$\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$  merupakan operator backshift untuk *Autoregressive*,



$\theta(B) = 1 - \theta_1 B + \theta_2 B^2 + \dots - \theta_q B^q$  merupakan operator backshift untuk *moving average* ,  
dan  $(1 - B)^d$  merupakan proses *differencing* orde ke - d

Jika polinomial  $\phi(B)$  memiliki sifat tertentu, maka proses AR(p) akan stasioner

Berikut ini adalah beberapa tahap untuk penetapan model ARIMA yang sesuai

1. Tahap Identifikasi

Akan dilakukan pengidentifikasian jenis model yang dianggap sesuai

2. Tahap Penaksiran dan Pengujian

Pada tahap ini dilakukan penaksiran terhadap parameter dalam model dan dilakukan diagnose checking untuk menyelidiki kelayakan model

3. Tahap Penerapan

Setelah mendapat model yang sesuai ,Langkah selanjutnya dalam analisis runtun waktu adalah melakukan peramalan (Hendikawati, 2015)

## 2.11 Estimasi

Estimasi merupakan salah satu tahap penting dalam kasus peramalan . Estimasi adalah proses meperkirakan nilai suatu parameter populasi yang tidak diketahui dari hasil nilai statistik. Pada kasus peramalan ini, populasi yang digunakan berupa data runtun waktu. Berikut akan dibahas beberapa estimasi model dan fungsi yang digunakan dalam proses peramalan

### 1. Estimasi Rata – rata (*Mean*)

Misalnya  $\mu = E(X_t)$  merupakan fungsi mean dari suatu proses (W-S) stasioner. Diberikan data  $X_1, X_2, \dots, X_n$ , maka penduga untuk fungsi mean diberikan oleh

$$\bar{X}_n = \frac{1}{n} \sum_{t=1}^n X_t \quad (2.10)$$

Catatan : didapatkan  $(\bar{X}_n) \frac{1}{n} n\mu = \frac{1}{n} n\mu = \mu$  yang merupakan penduga tak bias untuk  $\mu$ .

### 2. Sampel Autokovariansi

Estimator untuk fungsi  $\gamma_h$  dapat didefinisikan sebagai berikut.

$$\hat{\gamma}_k = n^{-1} \sum_{t=1}^{n-k} (X_t - \bar{X}_n) (X_{t+k} - \bar{X}_n) \quad 0 \leq k \leq n-1$$

atau

$$\hat{\gamma}_k = \frac{1}{n} \sum_{t=1}^{n-k} (X_t - \bar{X}_n) (X_{t+k} - \bar{X}_n) \quad (2.11)$$

Keterangan :

$\hat{\gamma}_h$  = koefisien autovarian lag – h

$n$  = ukuran sampel

$\bar{X}$  = rata – rata pengamatan  $X_t$

$X_t$  = pengamatan pada waktu ke-t

$X_{t+h}$  = pengamatan pada waktu ke- t dan h , dengan  $h = 0, 1, 2, \dots$

### 3. Sampel Autokorelasi (ACF)

Koefisien fungsi autokorelasi  $\rho_k$  pada persamaan (2.4) dapat diduga dengan koefisien autokorelasi sampel, yaitu :

$$\hat{\rho}_k = \frac{\sum_{t=1}^{n-k} (X_t - \bar{X}_n)(X_{t+k} - \bar{X}_n)}{\sum_{t=1}^n (X_t - \bar{X}_n)^2} \quad (2.12)$$

dengan  $\hat{\rho}_k$  = koefisien autokorelasi pada lag-k

## **BAB III**

### **METODE PENELITIAN**

#### **3.1 Ruang Lingkup**

Pada laporan tugas akhir ini ruang lingkup kegiatan yang digunakan ini adalah data kasus positif Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta pada tahun 2021, yaitu dengan menggunakan analisis ARIMA Box-Jenkins. Adapun data penelitian yang digunakan adalah data kasus positif Covid-19 di DKI Jakarta tahun 2021 yang dimana data diperoleh dari laman riwayat file Covid-19 DKI Jakarta. Objek penelitian yang digunakan pada laporan tugas akhir ini adalah Provinsi DKI Jakarta

#### **3.2 Populasi dan Sampel Penelitian**

##### **3.2.1 *Populasi***

Populasi adalah wilayah generalisasi yang terdiri dari objek/subjek yang memiliki kualitas dan karakteristik tertentu yang ditetapkan oleh peneliti untuk dipahami dan ditarik kesimpulannya. Jadi populasi bukan hanya orang, tetapi juga objek dan benda – benda alam yang lain. Populasi juga bukan sekedar jumlah yang ada pada objek atau subjek yang dipelajari, tetapi meliputi seluruh karakteristik atau sifat yang dimiliki oleh subjek atau objek yang diteliti itu (Sugiyono,2004:72). Populasi adalah keseluruhan subjek penelitian (Arikunto, 2006:130). Populasi yang digunakan pada penelitian ini adalah kasus positif covid-19 setelah vaksinasi diberlakukan di DKI Jakarta

##### **3.2.2 *Sampel***

Sampel adalah sebagian dari jumlah dan karakteristik yang dimiliki oleh populasi yang diambil menurut prosedur tertentu sehingga dapat mewakili

populasinya. Sampel yang diambil dari populasi tersebut harus betul – betul representative dan dapat mewakili tersebut (Siyoto,2015,p 64). Dalam hal ini teknik yang digunakan untuk menentukan sampel adalah teknik *non probability sampling*. Teknik sampling nonprobabilitas adalah teknik pengambilan sampel yang ditemukan atau ditentukan sendiri oleh peneliti atau menurut pertimbangan pakar . Sampel yang digunakan pada penelitian ini adalah kasus positif Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta dari tanggal 17 Februari 2021 – 3 September 2021

### **3.3 Data Penelitian**

Data adalah segala fakta dan angka yang dapat dijadikan bahan untuk menyusun suatu informasi. Sehingga dapat diartikan bahwa informasi adalah data yang sudah diolah untuk keperluan tertentu (Arikunto, 2006). Data yang akan dianalisis adalah data jumlah kasus positif virus Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta periode februari 2021 hingga september 2021

### **3.4 Variabel Penelitian**

Variabel adalah suatu karakteristik dari suatu obyek yang nilainya untuk tiap obyek bervariasi dan dapat diamati/diobservasi atau dihitung atau diukur (Sukestiyarno, 2013, p.1) . Variabel sebagai segala sesuatu yang diproses melalui informasi tentang suatu hal dari penelitian untuk dipelajari dan mendapatkan hasil dari penelitian tersebut. Yang mana akan ada kesimpulan dari proses penelitiannya (Sugiyono,2010) . Variabel yang digunakan dalam tugas akhir ini adalah jumlah kasus positif Covid-19 di DKI Jakarta pada tahun 2021 periode februari 2021 hingga september 2021

### **3.5 Metode Pengumpulan Data**

Metode pengumpulan data yang digunakan dalam penyusunan tugas akhir ini adalah sebagai berikut.

#### 1. Metode Dokumentasi

Metode pengumpulan data yang dilakukan dalam penelitian ini menggunakan metode dokumentasi . Dengan menggunakan metode ini akan didapatkan data tentang kasus positif Covid-19 di DKI Jakarta. Data ini diperoleh dari laman resmi riwayat file Covid-19 DKI Jakarta

### 3.6 Analisis Data

#### 1. Identifikasi Model

Langkah pertama yaitu menyiapkan data yang akan digunakan dan mengidentifikasi model runtun waktu. Identifikasi model dilakukan dengan cara membuat plot kemudian dari plot tersebut diidentifikasi apakah ada tren, komponen musiman, kestasioneran dalam *mean* dan variansi. Identifikasi model tidak hanya dilakukan dengan melihat plot data saja, melainkan disesuaikan dengan pengetahuan mengenai data yang akan dianalisis. tahapan identifikasi model lainnya seperti transformasi data, operasi *difference*, membuang komponen tren, membuang komponen musiman , dan lain – lain . kestasioneritasan data dapat dilihat dengan menggunakan uji unit root terhadap data ataupun dengan melihat bentuk fungsi sampel ACF dan fungsi sampel PACF .

**Tabel 3. 1 Plot Sampel ACF dan Pacf**

Proses	Sampel ACF	Sampel PACF
--------	------------	-------------

WN	Tidak ada yang melewati batas	Tidak ada yang melewati batas interval pada lag $> 0$
Ar(p)	Meluruh menuju nol secara eksponensial	Diatas batas interval maksimum sampai lag ke p dan di bawah batas pada lag $> p$
MA(q)	Diatas batas interval maksimum sampai lag ke q dan di bawah batas pada lag $> q$	Meluruh menuju nol secara eksponensial
ARMA(p,q)	Meluruh menuju nol secara eksponensial	Meluruh menuju nol secara eksponensial

## 2. Estimasi Parameter Model

Pada tahapan ini , estimasi parameter dari model dapat dilakukan dengan beberapa metode seperti metode *Hannan Rissanen*, Kuadrat kecil (*Least Square* ), *Maximum Likelihood Estimator* (MLE) , dan lain – lain. Dalam tugas akhir ini, metode estimasi yang digunakan adalah *Maximum Likelihood Estimator* (MLE)

## 3. Pemeriksaan Diagnostik dan Pemilihan Model Terbaik

Tahap selanjutnya adalah melakukan pengecekan diagnostic dari model yang sudah diestimasi . pada tahap ini beberapa uji yang digunakan yaitu sebagai berikut.

- a. Uji White Noise

Pengujian uji white noise menggunakan uji statistic Box-Pierce residual

$$1. H_0 : \rho_1 = \rho_2 = \rho_3 = \dots = \rho_k = 0$$

$H_0$  : Residual memenuhi proses *White Noise*

$$H_1 : \exists \rho_k \neq 0, k = 1, 2, \dots, K$$

$H_1$  : Residual tidak memenuhi proses *White Noise*

$$2. \alpha = 0.05$$

3. Statistik Uji (Box- Pierce)

$$Q_k = n(n+2) \sum_{k=1}^K \frac{r_k^2}{n-k'}$$

Keterangan :

$Q_k$  = Uji (Box-Pierce)

$n$  = Banyaknya observasi dalam runtun waktu

$k$  = Banyaknya lag yang diuji

$r_k$  = Nilai koefisien autokorelasi pada lag k

4. Wilayah kritis

$H_0$  ditolak jika  $Q < X^2(df)$ , dengan  $df = K - p$ ,

( $p$  = *banyaknya parameter*) atau p-value  $> \alpha$

5. Kesimpulan

b. Uji Normalitas Residual

$$1. H_0 : F(x) = F_0(x)$$

$H_0$  : Residual berdistribusi normal

$$H_1 : F(x) \neq F_0(x)$$

$H_1$  : Residual tidak berdistribusi normal

$$2. \alpha = 0.05$$

3. Statistik Uji

$$D_{hitung} = \text{maksimum } |F_n(x) - F_0(x)|$$



Keterangan :

$F_n(x)$  = fungsi distributif kumulatif berdasarkan data sampel

$F_0(x)$  = fungsi distributif kumulatif dibawah  $H_0$ ,  $P(Z < Z_t)$

$F_0(x) = P(Z < Z_t)$  nilai Z diperoleh dari

$$Z = \frac{X_i - \bar{X}}{s},$$

Keterangan :

$\bar{X}$  = Rata – rata sampel

$S$  = Standar deviasi sampel

#### 4. Wilayah Kritis

$H_0$  ditolak (residual tidak berdistribudi normal) jika  $D_{hitung} >$

$D_{(a,n)}$  > atau p – value  $> \alpha$ , dengan n adalah ukuran sampel

#### 5. Kesimpulan

Jika model yang diidentifikasi tidak memenuhi asumsi diatas, model tersebut tidak dapat digunakan dan harus mengulang proses identifikasi untuk menemukan model lain yang mungkin sesuai untuk data

Proses selanjutnya menentukan kriteria informasi seerti Akaike Information Criteria (AIC) . Metode AIC merupakan suatu kriteria pemilihan model terbaik yang diperkenalkan oleh peneliti bernama Akaike afn Schwarz pada tahun 1973. Metode AIC didasarkan pada metode maximum likelihood estimation (MLE). Kriteria ini mempertimbangkan banyaknya parameter dalam model. Kriteria AIC dapat dituliskan sebagai berikut(Fathurahman, 2009).

$$AIC = \log \hat{\sigma}_k^2 + \frac{n + 2k}{n}$$

Keterangan :

$\hat{\sigma}_k^2$  = penduga maximum likelihood

$n$  = banyaknya data runtun waktu

$k$  = banyaknya parameter dari model

Selanjutnya , pengukuran akurasi peramalan lainnya yaitu *Root Mean Square Error* (RMSE) . RMSE merupakan cara sederhana untuk mengukur kesalahan suatu model. RMSE digunakan untuk mengevaluasi kinerja model dalam hal kesesuaian dengan data atau meramalkan data. Cara kerja RMSE yaitu menghitung selisih antara nilai yang diprediksi oleh model dan nilai sebenarnya (Voulgaraki, 2013).

$$RMSE = \sqrt{MSE} = \sqrt{\frac{\sum_{t=1}^n (x_t - f_t)^2}{n}}$$

Keterangan :

$n$  = nilai periode waktu

$x_t$  = nilai sebenarnya pada period ke-t

$f_t$  = nilai peramalan pada periode ke-t

#### 4. Peramalan dengan Model Terbaik

Tahap terakhir setelah model terbaik didapatkan adalah meramalkan sifat – sifat data dimasa datang. Peramalan adalah proses penaksiran suatu data dari model terbaik kemudian diperoleh prediksi data untuk beberapa waktu mendatang. Pada proses peramalan ditunjukkan bagaimana data yang lampau dimanfaatkan untuk memperoleh prediksi ramalan yang akan datang


## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Hasil Penelitian

##### 4.1.1 *Persiapkan Data dan Identifikasi Model*

Data yang digunakan dalam penelitian ini merupakan data jumlah kasus positif Covid-19 setelah diberlakukan nya program vaksinasi di DKI Jakarta selama 199 hari dari tanggal 17 Februari 2021 – 3 September 2021 . Data diolah menggunakan bantuan aplikasi R. Langkah pertama yang dilakukan adalah memanggil data Jumlah kasus positif Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta (Data Asli) kedalam aplikasi R dan selanjutnya membuat plot grafik dari data yang telah dipanggil .



**Gambar 4. 1 Plot Grafik Data Asli Kasus Positif Covid-19**


Pada gambar diatas dapat dilihat bahwa plot grafik menunjukkan data tidak stasioner dalam variansi maupun rataaan. Kemudian akan diidentifikasi kestasioneran pada data, langkah yang dapat dilakukan adalah menguji data

dengan menggunakan uji akar unit (*Augmented Dickey Fuller Test*). Dengan hipotesis sebagai berikut :

$H_0$  : Terdapat *unit roots*, data tidak stasioner

$H_1$  : Tidak terdapat *unit roots*, data stasioner

Adapun pengujian yang dilakukan dengan aplikasi R yaitu menggunakan perintah `adf.test()`. Berdasarkan uji akar unit (*Augmented Dickey Fuller Test*) tersebut pada lampiran 2 - Uji akar unit terhadap data asli, didapatkan nilai p-value = 0,9352. Dikarenakan p-value > 0,05 maka  $H_0$  diterima. Dengan demikian data tersebut tidak stasioner. Data yang tidak stasioner tersebut kemudian ditransformasi . Transformasi yang dilakukan yaitu transformasi akar dengan perintah `sqrt()`. Selanjutnya dilakukan proses *differencing* pada data. *Differencing* dilakukan dengan menggunakan perintah `diff()`. Apabila data telah di *differencing* , maka dibuatlah plot grafik berdasarkan data tersebut dengan proses yang sama seperti sebelumnya dengan tujuan untuk melihat apakah data sudah stasioner atau belum. Hasil plot data setelah di *differencing* dapat dilihat pada gambar dibawah ini




**Gambar 4. 2 Plot Grafik Data Kasus Positif Covid-19 Setelah Ditransformasi dan Differencing**


Berdasarkan plot grafik di atas, data sudah terlihat stasioner dalam variasi dan rata-rata. Selanjutnya untuk memastikan kebenaran bahwa data sudah stasioner, dilakukan pengujian dengan uji akar unit (*Augmented Dickey Fuller Test*). Kemudian didapatkan nilai p-value sebesar 0,01. Dikarenakan p-value < 0,05 maka  $H_0$  ditolak. Dengan demikian data tersebut stasioner.

Tahap selanjutnya adalah menampilkan ACF dan PACF dari data yang sudah di *differencing* sebelumnya dengan perintah `acf()` dan `pacf()`.

#### **4.1.2 Estimasi Model**



**Gambar 4. 3 Plot ACF dari Data Kasus Positif Covid 19 Setelah Differencing**



**Gambar 4. 4 Plot PACF dari Data Kasus Positif Covid 19 Setelah Differencing**

Berdasarkan Plot ACF dan PACF yang dihasilkan, dugaan model yang memungkinkan adalah  $AR=2$  dan  $MA=3$ . Kesimpulan ini mengharuskan untuk mencoba melakukan tahap estimasi dan signifikansi model .

Pada tahap ini berdasarkan hasil identifikasi model, didapatkan 10 dugaan model ARIMA yang mungkin. Pemilihan model dilakukan dengan mengikuti prinsip parsimony. Prinsip ini menyatakan bahwa semakin sederhana sebuah model statistic dengan jumlah variabel dependen yang cukup informatif, semakin baik pula model statistic tersebut. Oleh karena itu, pada tahap ini akan dicoba kesepuluh modelnya dengan  $X_t = \text{sqrt}(\text{DataCovid})$ , yaitu :

- Model 1 : model ARIMA (0,1,1)
- Model 2 : model ARIMA (0,1,2)
- Model 3 : model ARIMA (0,1,3)
- Model 4 : model ARIMA (1,1,0)
- Model 5 : model ARIMA (1,1,1)
- Model 6 : model ARIMA (1,1,2)
- Model 7 : model ARIMA (1,1,3)
- Model 8 : model ARIMA (2,1,0)
- Model 9 : model ARIMA (2,1,1)
- Model 10 : model ARIMA (2,1,2)
- Model 11 : model ARIMA (2,1,3)

Selanjutnya uji signifikansi parameter – parameter yang telah ditentukan. Pada tahap ini digunakan perintah arima pada package forecast. Dibawah ini diberikan contoh estimasi parameter dari model 1 ARIMA (0,1,1) menggunakan fungsi arima

```
> library(forecast)

> dugaan1=arima(DataCovid_trans, order=c(0,1,1))

> summary (dugaan1)
```

Pada estimasi di atas, orde dari model ARIMA yang akan diestimasi dapat diisikan melalui pilihan order. Hasil dari estimasi ini akan disimpan kedalam

objek bernama `dugaan1`. Kemudian, *output* dari data dapat ditampilkan dengan perintah `summary` dan diperoleh hasil sebagai berikut.

Call:

```
arima(x = DataCovid_trans, order = c(0, 1, 1))
```

Coefficients:

ma1

-0.4892

s.e. 0.0629

sigma^2 estimated as 71.19: log likelihood = -703.36, aic = 1410.71

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1553466	8.416208	6.032274	-3.831606	15.97542	0.9582944

ACF1

Training set 0.05135507

Selanjutnya lakukan proses yang sama seperti langkah yang sebelumnya untuk dapat hasil estimasi parameter – parameter dari model dugaan lainnya. Kemudian akan diperoleh hasil sebagai berikut.



Tabel 4. 1 Hasil Estimasi Model

	ARIMA (0,1,1)	ARIMA (0,1,2)	ARIMA (0,1,3)	ARIMA (1,1,0)	ARIMA (1,1,1)
$\phi_1$				-0,3094 0,0682	0,1311 0,113
$\phi_2$					
$\theta_1$	-0,4892 0,0629	-0,4067 0,0796	-0,4314 0,075		-0,5724 0,0832
$\theta_2$		-0,108 0,074	-0,2278 0,0788		
$\theta_3$			0,1619 0,0758		
<b>RMSE</b>	8,41621	8,37079	8,2683	8,74316	8,38854
<b>AIC</b>	1410,71	1410,55	1407,82	1425,63	1411,39

ARIMA (1,1,2)	ARIMA (1,1,3)	ARIMA (2,1,0)	ARIMA (2,1,1)	ARIMA (2,1,2)	ARIMA (2,1,3)
-0,5374 0,1908	0,9217 0,0502	-0,3951 0,0681	-0,034 0,1856	1,042 0,0992	0,6083 0,2271
		-0,3002 0,0691	-0,181 0,1016	-0,4839 0,1035	0,2976 0,2147
0,1414 0,1751	-1,4019 0,0897		-0,3938 0,1825	-1,518 0,0779	-1,1007 0,2084
-3872 0,0825	0,2287 0,1379				-0,2476 0,3119
	0,2524 0,0755				0,4455 0,1284
8,29805 1409,15	8,00476 1397,62	8,35103 1409,65	8,31973 1410,19	8,06026 1400,19	7,98021 1398,42

#### 4.1.3 Pemeriksaan Diagnostik dan Pemilihan Model terbaik

Pada tahap ini, diperlukan data residual dari parameter – parameter model yang telah terbentuk untuk melakukan pemeriksaan diagnostik. Kemudian, berdasarkan data residual tersebut dilakukan beberapa uji dan analisis. Uji analisis itu berupa uji white noise dan uji normalitas. Dibawah ini diberikan contoh uji white noise dan uji normalitas dari model dugaan1 ARIMA (1,1,0) menggunakan fungsi arima. Dengan perintah Box.test() dan uji normalitas dengan menggunakan Kolmogorov Smirnov ks.test()

```
> library(tseries)

> residual_1=resid(dugaan1)

> residual_1

> Box.test(residual_1,type="Ljung")

Box-Ljung test

data: residual_1

X-squared = 0.53278, df = 1, p-value = 0.4654

> ks.test(residual_1,"pnorm", mean(residual_1),sd(residual_1))

One-sample Kolmogorov-Smirnov test

data: residual_1

D = 0.099253, p-value = 0.03965

alternative hypothesis: two-sided
```

Sementara itu analisis yang digunakan adalah dengan melakukan uji Q-Ljung\_Box dan plot ACF/PACF untuk residual, untuk melihat apakah korelasi serial dalam residual dari model yang diamati . Pada tahap ini , digunakan

perintah `tsdiag`. Contohnya, untuk hasil estimasi model dugaan 1 dapat digunakan perintah berikut.

```
>tsdiag(dugaan1)
```

Apabila ingin menampilkan nilai statistic ACF beserta nilai dari statistic Ljung-Box dari residual model 1 dapat digunakan fungsi sebagai berikut.

```
>hasil_1=acfStat(dugaan1$residual)
```

Selanjutnya, lakukan hal yang sama terhadap model lain . Hasil uji diagnostik dapat dilihat pada tabel 4.2

**Tabel 4. 2 Uji White Noise dan Uji Kolmogorv Smirnov**

	<b>Model</b>	<b>Uji W.N</b>	<b>Uji K.S</b>	<b>Uji Signifikansi Paramater</b>
1	(0,1,1)	Memenuhi	Tidak Memenuhi	Tidak Memenuhi
2	(0,1,2)	Memenuhi	Tidak Memenuhi	Tidak Memenuhi
3	(0,1,3)	Memenuhi	Memenuhi	Tidak Memenuhi
4	(1,1,0)	Memenuhi	Tidak Memenuhi	Tidak Memenuhi
5	(1,1,1)	Memenuhi	Tidak Memenuhi	Tidak Memenuhi
6	(1,1,2)	Memenuhi	Memenuhi	Tidak Memenuhi
7	(1,1,3)	Memenuhi	Memenuhi	Tidak Memenuhi
8	(2,1,0)	Memenuhi	Tidak Memenuhi	Tidak Memenuhi
9	(2,1,1)	Memenuhi	Memenuhi	Tidak Memenuhi
10	(2,1,2)	Memenuhi	Memenuhi	Memenuhi
11	(2,1,3)	Memenuhi	Memenuhi	Tidak Memenuhi


Berdasarkan tabel diatas dapat disimpulkan bahwa model ARIMA(2,1,2) merupakan model yang terbaik karena memenuhi uji signifikansi parameter, White Noise, dan Uji normalitas

#### **4.1.4 Peramalan**

Setelah melakukan uji identifikasi model, estimasi model, dan verifikasi model maka didapatkan model terbaik yaitu model ARIMA(2,1,2) . Selanjutnya dari model terbaik yang didapat akan digunakan untuk meramalkan kasus positif Covid-19 setelah vaksinasi diberlakukan di DKI Jakarta yang terhitung mulai dari tanggal 17 february 2021 . Untuk mendapatkan hasil dari peramalan digunakan perintah `forecast()`. Setelah diperoleh hasil peramalan, kemudian dibuat plot grafik nya

**Tabel 4. 3 Data Hasil Peramalan Sebelum Diubah ke Data Asli**

t	point Forecast
200	19,40281
201	20,07063
202	20,33961
203	20,29680
204	20,12200
205	19,96052
206	19,87680
207	19,86768
208	19,89869
209	19,93543
210	19,95871
211	19,96520



**Gambar 4. 5 Plot Data Peramalan Kasus Positif Covid-19**

## 4.2 Pembahasan

Berdasarkan hasil penelitian di atas akan dibahas model ARIMA yang paling cocok untuk digunakan dalam meramalkan jumlah positif virus covid - 19 setelah vaksinasi diberlakukan di DKI Jakarta .Berdasarkan hasil analisis menggunakan R diperoleh sebagai berikut.

1. Dari hasil identifikasi model diatas , ada satu model yang teridentifikasi yaitu ARIMA (2,1,2) yang memiliki nilai RMSE 8,060256 dan AIC 1400,19. Dikarenakan  $X_t^*$  merupakan data yang sudah mengalami transformasi akar , maka  $X_t^* = \sqrt{X_t}$  . Jadi diperoleh persamaan model terbaik :

$$\begin{aligned}
 X_t^* &= \phi_1 X_{t-1} + \phi_2 X_{t-2} + \omega_t - \theta_1 \omega_{t-1} - \theta_2 \omega_{t-2} \\
 X_t^* &= 1.0427X_{t-1} - 0.4839X_{t-2} + \omega_t - 1.5182\omega_{t-1} \\
 &\quad - 0.7861\omega_{t-2} \\
 &\text{Atau} \\
 X_t &= (1.0427X_{t-1} - 0.4839X_{t-2} + \omega_t - 1.5182\omega_{t-1} \\
 &\quad - 0.7861\omega_{t-2})^2
 \end{aligned}$$

2. Data yang digunakan dalam peramalan adalah data asli, bukan menggunakan data yang sudah mengalami transformasi akar  $X_t^*$ . Oleh karena itu, hasil peramalan harus dikuadratkan agar sesuai dengan data

asli . Jadi, hasil peramalan data covid untuk waktu 12 waktu kedepan dengan menggunakan model ARIMA (2,1,2) adalah sebagai berikut.

**Tabel 4. 4 Data Asli Hasil Peramalan**

t	$X_t$
200	376,47
201	402,83
202	413,70
203	411,97
204	404,89
205	398,42
206	395,09
207	394,72
208	395,95
209	397,42
210	398,33
211	398,61

Keterangan :

t = hari ke-

$X_t$  = data hasil peramalan ke-

## BAB V

### PENUTUP

#### 5.1 Kesimpulan

Berdasarkan hasil analisis yang telah diperoleh pada pembahasan diatas untuk peramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta , maka dapat diambil kesimpulan sebagai berikut.

1. Peramalan dilakukan dengan menggunakan Metode Arima (*Autoregressive Integrated Moving Average*) Box-Jenkins dan dihasilkan model terbaik yaitu model ARIMA(2,1,2)
2. Hasil dari analisis diatas didapatkan model terbaik yaitu ARIMA(2,1,2) dengan model  $X_t^* = 1.0427X_{t-1} - 0.4839X_{t-2} + \omega_t - 1.5182\omega_{t-1} - 0.7861\omega_{t-2}$  yang digunakan untuk peramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta selama 12 periode
3. Berdasarkan hasil peramalan dari model terbaik didapatkan nilai peramalan jumlah kasus positif virus covid-19 setelah vaksinasi diberlakukan di DKI Jakarta selama 12 periode sebagai berikut.

Hari ke-	Peramalan Jumlah
200	376,47
201	402,83
202	413,70
203	411,97
204	404,89

205	398,42
206	395,09
207	394,72
208	395,95
209	397,42
210	398,33
211	398,61

---

## 5.2 Saran

1. Peneliti atau pembaca diharapkan mencoba untuk mencari metode lain ataupun mengembangkan metode ARIMA dengan memadukan variabel lainnya guna untuk mendapatkan hasil peramalan yang lebih akurat apabila ingin mencoba meneliti ini pada penelitian selanjutnya
2. Selain itu, peneliti atau pembaca diharapkan untuk lebih lanjut membahas aplikasi metode ARIMA dengan menggunakan program – program lainnya, selain program R



## DAFTAR PUSTAKA

- Arikunto, S. (2006). *Suatu Pendekatan Praktik*. Rineka Cipta.
- Bialek, S., Boundy, E., Bowen, V., & Chow, N. (2020). Severe Outcomes Among Patients with Coronavirus Disease 2019 (COVID-19) — United States, February 12–March 16, 2020. *MMWR. Morbidity and Mortality Weekly Report*, 69(12), 343–346. <https://doi.org/10.15585/mmwr.mm6912e2>
- Brockwell, P. J., & Davis, R. A. (2002). *Introduction To Time Series and Forecasting*. Inc. New York.
- CDC Goverment. (2019). *Symptoms of COVID-19*. Cdc.Gov.  
<https://www.cdc.gov/coronavirus/2019-ncov/symptoms-testing/symptoms.html>
- Edwards, K. M., & Hackell, J. M. (2020). Committee on Infectious Diseases, the Committee on Practice and Ambulatory Medicine. Countering vaccine hesitancy. *Pediatrics*, 138(3). <https://doi.org/10.1542/peds.2016-2146>
- Fathurahman. (2009). *Pemilihan Model Regresi Terbaik Menggunakan Metode Akaike's Information Criteria dan Schwarz Information Criterion*. Universitas Mulawarman.
- Firdaus, M. (2004). *Ekonometrika: suatu pendekatan aplikatif*. Bumi Aksara.
- Handayani, D., Hadi, D. R., Isbaniah, F., Burhan, E., & Agustin, H. (2020). Penyakit Virus Corona 2019. *Respirologi Indonesia KEMENRISTEK DIKTI*, 40(1), 9–12.
- Heizer, J., & Render, B. (2009). *Manajemen Operasi, Buku 1 Edisi 9*. Jakarta: Salemba Empat. Salemba Empat.
- Hendikawati. (2015). *Peramalan Data Runtun Waktu Metode dan Aplikasinya dengan Minitab & Eviews*.

- Kolker, A. (2012). *Forecasting Time Series. Dalam Healthcare: Management Engineering: What Does This Fancy Term Really Mean?: The Use of Operations Management Methodology for Quantitative Decision Making in Healthcare Setting* (p. 89). Springer New York.
- Lestari, N., & Wahyuningsih, N. (2012). Peramalan Kunjungan Wisata dengan Pendekatan Model SARIMA ( Studi kasus : Kusuma Agrowisata ). *Jurnal Sains Dan Seni ITS*, 1(1), 29–33.
- Ludwig, S., & Zarbock, A. (2020). Coronaviruses and SARS-CoV-2: A Brief Overview. *Anesthesia and Analgesia*, XXX(Xxx), 93–96.  
<https://doi.org/10.1213/ANE.00000000000004845>
- Makmun, A., & Hazhiyah, S. F. (2020). Tinjauan Terkait Pengembangan Vaksin Covid 19. *Molucca Medica*, 13, 52–59.  
<https://doi.org/10.30598/molmed.2020.v13.i2.52>
- Makridakis, Spyros, Wheelwright, & C., S. (1999). *Metode dan Aplikasi Peramalan*. Erlangga.
- Perdana, A. A. R. (2017). *Penerapan Metode ARIMA untuk Peramalan Suplai Suku Cadang Kendaraan Bermotor*.
- Rosnani, G. (n.d.). Sistem Produksi. In 2007. Graha Ilmu.
- Rudianto, Zainal, Lutfi, Thariq, Harahap, Nasution, Priadi, Hendra, Adhani, & Yulhasni. (2020). *Kita dan Corona Catatan Kritis di Tengah Pandemi Covid-19*. 1997–2000.  
<https://publication.umsu.ac.id/index.php/ht/article/download/510/483>
- Saputro, G. A., & Asri, M. (2000). *Anggaran Perusahaan Edisi #*. BPFE.
- Soejati. (1987). *Analisis Runtun Waktu*. Universitas Terbuka.
- Sudjana. (1989). *Metoda Statistika Edisi IV*. Tarsito.

- Suhartono, & Subanar. (2009). *Wavelet Neural Networks untuk Peramalan Data Time Series Finansil*.
- Trujillo, K. L., & Motta, M. (2020). *A majority of vaccine skeptics plan to refuse a COVID-19 vaccine, a study suggests, and that could be a big problem*.
- Voulgaraki. (2013). *Forecasting sales and intervention analysis of durable products in the Greek market. Empirical evidence from the new car retail sector*. London School of Economics and Political Science.
- Wei. (1994). *Time Series Analysis: Univariate and Multivariate Method*. Addison Wesley Publishing Company.
- Winarno, W. W. (2009). *Analisis Ekonometrika dan Statistika dengan Eview, Edisi kedua*. UPP STIM YKPN.
- Y, B., L, Y., & T, W. (2020). Presumed Asymptomatic Carrier Transmission of COVID-19. *Jama Network*, 1406–1407. <https://doi.org/10.1056/nejmoa2001316>

## LAMPIRAN

### Lampiran 1

Kasus Positif Covid Harian
1445
373
1920
2872
2720
2471
782
782
1581
1661
1737
2098
2048
578
1437
2008
1159
1616
1834
1783
867
1754
1873
1040
1204
934
1109
927
1330
1092
1588

1638
1937
1474
762
1381
1726
1304
815
890
762
198
965
1337
1240
510
676
523
281
651
1239
1013
977
1031
778
827
661
1330
979
1037
750
973
762
602
1266
884
907

896
749
918
639
987
789
926
554
757
521
845
905
783
732
809
694
489
656
785
632
227
161
421
397
539
695
856
932
867
819
406
617
940
693
807
984

726
755
601
714
906
1317
1019
1197
519
1371
2096
2293
2455
2769
2722
2119
2376
4144
4737
4895
5582
3221
3789
7505
7502
6934
9271
9394
8348
6213
7680
7541
9399
9702
10485
10903

9439
9366
12974
13112
12920
13133
14619
9439
10092
11876
10421
10001
9128
5000
7379
5904
2160
8033
8360
5393
5432
1980
5525
3845
3454
3327
2701
1410
3567
1789
2311
2185
2008
1649
727
1601



1679
1172
1210
1363
1182
513
655
1029
731
969
891
701
485
484
789
574
638
468
474
341
399
673
430
343

## Lampiran 2

### 1. Persiapkan Data dan Identifikasi Model

- Memanggil data kemudian membuat plot grafik

```
>DataCovid <- ts(dataauji$`Kasus Positif Covid Harian`)
```

```
>ts.plot(DataCovid, col="blue", ylab="Jumlah Kasus Covid", xlab="Hari" ,
main="Plot Peramalan Kasus Positif Covid-19")
```

```
>DataCovid
```

Time Series:

Start = 1

End = 199

Frequency = 1

[1] 1445 373 1920 2872 2720 2471 782 782 1581 1661 1737  
 [12] 2098 2048 578 1437 2008 1159 1616 1834 1783 867 1754  
 [23] 1873 1040 1204 934 1109 927 1330 1092 1588 1638 1937  
 [34] 1474 762 1381 1726 1304 815 890 762 198 965 1337  
 [45] 1240 510 676 523 281 651 1239 1013 977 1031 778  
 [56] 827 661 1330 979 1037 750 973 762 602 1266 884  
 [67] 907 896 749 918 639 987 789 926 554 757 521  
 [78] 845 905 783 732 809 694 489 656 785 632 227  
 [89] 161 421 397 539 695 856 932 867 819 406 617  
 [100] 940 693 807 984 726 755 601 714 906 1317 1019  
 [111] 1197 519 1371 2096 2293 2455 2769 2722 2119 2376 4144  
 [122] 4737 4895 5582 3221 3789 7505 7502 6934 9271 9394 8348  
 [133] 6213 7680 7541 9399 9702 10485 10903 9439 9366 12974 13112  
 [144] 12920 13133 14619 9439 10092 11876 10421 10001 9128 5000 7379  
 [155] 5904 2160 8033 8360 5393 5432 1980 5525 3845 3454 3327  
 [166] 2701 1410 3567 1789 2311 2185 2008 1649 727 1601 1679  
 [177] 1172 1210 1363 1182 513 655 1029 731 969 891 701

[188] 485 484 789 574 638 468 474 341 399 673 430

[199] 343

- Uji Augmented Dickey Fuller terhadap data asli

```
> library(tseries)
```

```
> adf.test(DataCovid)
```

### Augmented Dickey-Fuller Test

```
data: DataCovid
```

```
Dickey-Fuller = -1.0056, Lag order = 5, p-value = 0.9352
```

```
alternative hypothesis: stationary
```

```
> acf(DataCovid)
```

```
> pacf(DataCovid)
```

- Transformasi akar terhadap data asli

```
> DataCovid_trans=sqrt(DataCovid)
```

- Proses differencing terhadap data hasil transformasi akar

```
> DataCovid_diff=diff(DataCovid_trans)
```

- Membuat plot grafik berdasarkan data hasil differencing

```
> ts.plot(DataCovid_trans, col="blue", ylab="Jumlah Kasus Covid",  
xlab="Hari" , main="Plot Peramalan Kasus Positif Covid-19")
```

- Kembali menguji Uji Augmented Dickey Fuller terhadap data hasil differencing

```
> adf.test(DataCovid_diff)
```

### Augmented Dickey-Fuller Test

data: DataCovid\_diff

Dickey-Fuller = -7.2057, Lag order = 5, p-value = 0.01

alternative hypothesis: stationary

Warning message:

In adf.test(DataCovid\_diff) : p-value smaller than printed p-value

- Membuat plot grafik ACF berdasarkan data hasil differencing  
> acf(DataCovid\_diff)
- Membuat plot grafik PACF berdasarkan data hasil differencing  
> pacf(DataCovid\_diff)

## 2. Estimasi Model

- Hasil  
Model 2 ARIMA (0,1,1)  
> dugaan1=arima(DataCovid\_trans, order=c(0,1,1))  
> summary(dugaan1)

Call:

arima(x = DataCovid\_trans, order = c(0, 1, 1))

Coefficients:

ma1  
-0.4892

s.e. 0.0629

sigma^2 estimated as 71.19: log likelihood = -703.36, aic = 1410.71

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1553466	8.416208	6.032274	-3.831606	15.97542	0.9582944
ACF1						
Training set	0.05135507					

Model 2 ARIMA (0,1,2)

```
> dugaan2=arima(DataCovid_trans, order=c(0,1,2))
> summary(dugaan2)
```

Call:

```
arima(x = DataCovid_trans, order = c(0, 1, 2))
```

Coefficients:

	ma1	ma2
	-0.4067	-0.108
s.e.	0.0796	0.074

sigma^2 estimated as 70.42: log likelihood = -702.28, aic = 1410.55

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1674454	8.370787	6.009805	-3.835606	15.90933	0.9547249
ACF1						
Training set	-0.01642667					

Model 3 ARIMA (0,1,3)

```
> dugaan3=arima(DataCovid_trans, order=c(0,1,3))
```

```
> summary(dugaan3)
```

Call:

```
arima(x = DataCovid_trans, order = c(0, 1, 3))
```

Coefficients:

	ma1	ma2	ma3
	-0.4314	-0.2278	0.1619
s.e.	0.0750	0.0788	0.0758

sigma^2 estimated as 68.71: log likelihood = -699.91, aic = 1407.82

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1584297	8.268303	5.986859	-3.767288	15.9441	0.9510798

ACF1

Training set 0.007416635

Model 4 ARIMA (1,1,0)

```
> dugaan4=arima(DataCovid_trans, order=c(1,1,0))
```

```
> summary(dugaan4)
```

Call:

```
arima(x = DataCovid_trans, order = c(1, 1, 0))
```

Coefficients:

```

      ar1
-0.3094
s.e. 0.0682

```

sigma^2 estimated as 76.83: log likelihood = -710.82, aic = 1425.63

Training set error measures:

```

      ME   RMSE   MAE   MPE   MAPE   MASE
Training set -0.1200146 8.743159 6.116516 -3.417508 16.18709 0.9716771
      ACF1
Training set -0.08588393

```

Model 5 ARIMA (1,1,1)

```

> dugaan5=arima(DataCovid_trans, order=c(1,1,1))
> summary(dugaan5)

```

Call:

```
arima(x = DataCovid_trans, order = c(1, 1, 1))
```

Coefficients:

```

      ar1   ma1
0.1311 -0.5724
s.e. 0.1130 0.0832

```

sigma^2 estimated as 70.72: log likelihood = -702.7, aic = 1411.39

Training set error measures:

```

      ME   RMSE   MAE   MPE   MAPE   MASE
Training set -0.1634915 8.388535 6.017337 -3.843398 15.92477 0.9559214

```

ACF1

Training set 0.01195282

Model 6 ARIMA (1,1,2)

```
> dugaan6=arima(DataCovid_trans, order=c(1,1,2))
```

```
> summary(dugaan6)
```

Call:

```
arima(x = DataCovid_trans, order = c(1, 1, 2))
```

Coefficients:

```
      ar1    ma1    ma2
-0.5374 0.1414 -0.3872
s.e. 0.1908 0.1751 0.0825
```

sigma^2 estimated as 69.21: log likelihood = -700.57, aic = 1409.15

Training set error measures:

```
      ME    RMSE    MAE    MPE    MAPE    MASE
Training set -0.1648895 8.298047 6.003189 -3.789105 15.92022 0.9536739
```

ACF1

Training set -0.01859072

Model 7 ARIMA (1,1,3)

```
> dugaan7=arima(DataCovid_trans, order=c(1,1,3))
```

```
> summary(dugaan7)
```

Call:

```
arima(x = DataCovid_trans, order = c(1, 1, 3))
```



Coefficients:

	ar1	ma1	ma2	ma3
	0.9217	-1.4019	0.2287	0.2524
s.e.	0.0502	0.0897	0.1379	0.0755

sigma^2 estimated as 64.4: log likelihood = -693.81, aic = 1397.62

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1008231	8.004761	5.751517	-2.923203	15.29945	0.913693
	ACF1					
Training set	-0.01618221					

Model 8 ARIMA (2,1,0)

```
> dugaan8=arima(DataCovid_trans, order=c(2,1,0))
> summary(dugaan8)
```

Call:

```
arima(x = DataCovid_trans, order = c(2, 1, 0))
```

Coefficients:

	ar1	ar2
	-0.3951	-0.3002
s.e.	0.0681	0.0691

sigma^2 estimated as 70.09: log likelihood = -701.82, aic = 1409.65

Training set error measures:

```

      ME   RMSE   MAE   MPE   MAPE   MASE
Training set -0.137493 8.351028 5.996561 -3.612058 16.04876 0.952621
      ACF1
Training set -0.009988643

```

Model 9 ARIMA (2,1,1)

```

> dugaan9=arima(DataCovid_trans, order=c(2,1,1))
> summary(dugaan9)

```

Call:

```
arima(x = DataCovid_trans, order = c(2, 1, 1))
```

Coefficients:

```

      ar1   ar2   ma1
      -0.0340 -0.1810 -0.3938
s.e.  0.1856  0.1016  0.1825

```

sigma^2 estimated as 69.57: log likelihood = -701.1, aic = 1410.19

Training set error measures:

```

      ME   RMSE   MAE   MPE   MAPE   MASE
Training set -0.1603611 8.319727 5.996637 -3.801064 15.94177 0.9526331
      ACF1
Training set 0.004125804

```

Model 10 ARIMA (2,1,2)

```

> dugaan10=arima(DataCovid_trans, order=c(2,1,2))
> summary(dugaan10)

```

Call:

```
arima(x = DataCovid_trans, order = c(2, 1, 2))
```

Coefficients:

	ar1	ar2	ma1	ma2
	1.0423	-0.4839	-1.5180	0.7861
s.e.	0.0992	0.1035	0.0779	0.0657

sigma^2 estimated as 65.3: log likelihood = -695.09, aic = 1400.19

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1347265	8.060256	5.85129	-3.447529	15.52803	0.929543

ACF1

Training set -0.01839295

Model 11 ARIMA (2,1,3)

```
> dugaan11=arima(DataCovid_trans, order=c(2,1,3))
```

```
> summary(dugaan11)
```

Call:

```
arima(x = DataCovid_trans, order = c(2, 1, 3))
```

Coefficients:

	ar1	ar2	ma1	ma2	ma3
	0.6083	0.2976	-1.1007	-0.2476	0.4455
s.e.	0.2271	0.2147	0.2084	0.3119	0.1284

sigma^2 estimated as 64.01: log likelihood = -693.21, aic = 1398.42

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.1007652	7.980211	5.800393	-2.899139	15.38367	0.9214575

ACF1

Training set 0.003525919

### 3. Pemeriksaan Diagnostik dan Pemilihan Model

- Nilai residual Model

```
> residual_1=resid(dugaan1)
```

```
> residual_1
```

Time Series:

Start = 1

End = 199

Frequency = 1

```
[1]  0.03801313 -16.79795454  16.74117366  17.68624915   7.15961523
1.05301691
[7] -21.22843985 -10.38310047   6.71863103   4.28001821   3.01555813
5.60167573
[13]  2.19099724 -20.14146391   4.01383407   8.86632124  -6.42960957
3.01033122
[19]  4.09824535  1.40503982 -12.09343725  6.52034187  4.58685129  -
8.78545312
[25] -1.84778509 -5.04114476   0.27433174  -2.72078589  4.69160158  -
1.12881664
[31]  6.25212696  3.68076051   5.33961563  -3.00674942 -12.25912973
3.56083381
```

[37] 6.12515109 -2.43806148 -8.75532777 -2.99805831 -3.69503856 -  
15.34055054

[43] 9.48927927 10.14229950 3.60978994 -10.86470368 -1.89771474 -  
4.05908533

[49] -8.09166465 4.79356059 12.02952917 2.51254567 0.65836512  
1.17423276

[55] -3.64215434 -0.91662538 -3.49606024 9.04912589 -0.75375499  
0.54480489

[61] -4.54986191 1.58122772 -2.81513339 -4.44569862 8.87056523 -  
1.50966591

[67] -0.35415896 -0.35642059 -2.73974000 1.59049014 -4.24206767  
4.06307390

[73] -1.33993529 1.68566689 -6.06848942 1.00799029 -4.19514405  
4.19137934

[79] 3.06457262 -0.60202662 -1.22112358 0.79010684 -1.71256005 -  
5.06824441

[85] 1.01999032 2.90428890 -1.45759088 -10.78608036 -7.65401773  
4.08569817

[91] 1.40511816 3.97883669 5.09275102 5.38577482 3.90568152  
0.82667630

[97] -0.42231400 -8.67531180 0.44646206 6.03832434 -1.38084359  
1.40740431

[103] 3.64946914 -2.63922733 -0.75811777 -3.33279985 0.57521799  
3.66042680

[109] 7.98118052 -0.46467276 2.44861091 -10.61836353 9.05140927  
13.18262670

[115] 8.55154816 5.84571822 5.93280013 2.45356625 -4.94001600  
0.29519473

[121] 15.77407361 12.16794247 7.09043163 8.21683407 -13.93961507 -  
 2.01764748  
 [127] 24.08960509 11.76625878 2.41209274 14.19527880 7.58032338 -  
 1.84729854  
 [133] -13.44842184 2.23464716 0.29641326 10.25450087 6.56634184  
 7.10952365  
 [139] 5.49880876 -4.57314000 -2.61339835 15.84701168 8.35583486  
 3.24584313  
 [145] 2.52084770 7.54284263 -20.06491377 -6.51044255 5.33349283 -  
 4.28485238  
 [151] -4.17426077 -6.50629734 -28.01248367 1.48795291 -8.33577397 -  
 34.43918468  
 [157] 26.30507034 14.67331415 -10.81844785 -5.02685363 -31.66382786  
 14.34460093  
 [163] -5.30553190 -5.83255582 -3.94361822 -7.63805130 -18.15737787  
 13.29260956  
 [169] -10.92563499 0.43194932 -1.11758719 -2.47994506 -5.41591204 -  
 16.29416944  
 [175] 5.07916952 3.44761077 -5.05469741 -1.92196692 1.19363394 -  
 1.95472979  
 [181] -12.68689140 -3.26240477 4.88923716 -2.64941843 2.79577420  
 0.08842805  
 [187] -3.32996341 -6.08256068 -2.99803669 4.62263613 -1.86965644  
 0.38581108  
 [193] -3.43663241 -1.54281602 -4.06003348 -0.47719076 5.73383846 -  
 2.40106061  
 [199] -3.39067542

> residual\_2=resid(dugaan2)

```
> residual_2
```

```
Time Series:
```

```
Start = 1
```

```
End = 199
```

```
Frequency = 1
```

```
[1] 0.03801313 -17.23644256 18.15859989 14.87820222 6.37558638
1.71986044
[7] -20.35268945 -8.08333736 6.31446876 2.68845961 2.69690695
5.51353934
[13] 1.98416344 -19.81105000 6.02418045 7.21371130 -7.18273462
4.01339199
[19] 3.48227039 1.24974909 -11.89653361 7.73310434 3.25762131 -
8.86949172
[25] -0.80540422 -5.42243177 0.44823768 -3.25815038 4.74595266 -
1.84556762
[31] 6.56620273 3.09339136 5.50602409 -3.04563136 -11.43239651
4.57962351
[37] 5.01132528 -2.90189723 -8.20173366 -2.36390044 -4.07533135 -
15.44556760
[43] 10.27222591 8.01015181 3.01504047 -10.53954049 -0.54357551 -
4.48978795
[49] -7.99060841 5.01749644 10.86237317 1.58716409 1.24755246
1.53087235
[55] -3.45930918 -0.37649288 -3.57428435 9.26510593 -1.79842525
1.18251237
[61] -4.52965830 2.09249951 -3.22674052 -4.15489603 9.00722364 -
2.63454807
[67] 0.28545285 -0.35154905 -2.67753300 1.80387039 -4.57560654
4.47218826
```

[73] -2.00280836 2.00951253 -6.29211099 1.63469280 -4.70280547  
4.50754923

[79] 2.33958434 -0.66301232 -0.94365317 0.93210417 -1.82188814 -  
4.87077207

[85] 1.32173776 2.41695323 -1.75267695 -10.52486638 -6.84713216  
3.90895669

[91] 0.25688656 3.81802110 4.72682032 5.22902045 3.90793486  
1.06992582

[97] 0.03033238 -8.34088168 1.30148237 5.44863509 -1.97830963  
1.86664815

[103] 3.50651040 -2.79691928 -0.22590484 -3.35580495 0.81644201  
3.34874296

[109] 7.64058327 -0.90009960 3.13482115 -10.63851737 10.25773310  
11.77778077

[115] 8.00015315 6.18758040 6.45328548 2.84380422 -4.28700465  
1.27535501

[121] 15.68544274 10.96817271 7.29216686 8.89809428 -13.55317963  
0.25028372

[127] 23.71501549 9.65346287 3.14262317 15.33560986 7.21217595 -  
0.96665597

[133] -12.15921153 3.76408875 -0.57881205 10.28053538 5.66839724  
7.31259354

[139] 5.60682936 -4.19335991 -1.47629803 16.07228227 6.98060502  
3.73250803

[145] 3.20463891 8.01591955 -20.14885244 -4.02367449 4.70644474 -  
5.41430656

[151] -3.77189127 -6.58285233 -27.91406304 3.12838170 -10.80528369 -  
34.41791436



```

[157] 27.98846665  9.47155439 -11.12249766 -3.23530320 -31.72143045
16.58426226
[163] -9.00316324 -5.10790373 -4.13978263 -7.94394845 -18.09856591
13.95688976
[169] -13.70626838  1.70950922 -2.11354366 -2.60817453 -5.49164668 -
16.15973207
[175]  5.88525121  1.61161604 -5.45033024 -1.49181527  0.93866375 -
2.31796219
[181] -12.57198152 -2.41922218  4.14390656 -3.61708968  3.06826681 -
0.42195577
[187] -3.21353242 -5.80603599 -2.73071054  4.35182788 -2.65599742
0.69015733
[193] -3.63146368 -1.26399324 -4.21144361 -0.34026367  5.37418834 -
3.05711582
[199] -2.87912278
>
> residual_3=resid(dugaan3)
> residual_3
Time Series:
Start = 1
End = 199
Frequency = 1
[1]  0.03801313 -16.63147935  17.70172388  12.81082191  10.52946744
2.42107840
[7] -20.35708373 -9.92875115  2.48531874  3.09987455  4.43303340
6.34265923
[13]  2.69493561 -19.32352714  5.11742898  4.27165436 -4.62894349
4.30312675

```

[19] 2.73565192 2.31038208 -11.85766168 7.40423813 1.51575738 -  
6.76825661

[25] -1.32362625 -6.49569438 0.73264016 -3.80447930 5.60013613 -  
1.99340145

[31] 7.83632487 2.64185805 6.78688055 -3.35807769 -11.11852190  
2.89717426

[37] 3.64381305 -1.40186636 -7.80645848 -2.99225284 -5.07078806 -  
15.13806989

[43] 9.79237473 7.09700722 6.39238072 -9.84180924 -0.52155079 -  
6.63314277

[49] -7.49258235 4.09282615 10.81738886 3.44028689 2.71508257  
1.05547812

[55] -3.69977023 -0.93021627 -4.46277371 9.22132617 -2.06847635  
2.84475208

[61] -5.55370986 2.39417396 -4.28175985 -3.47089854 8.18477083 -  
2.41548031

[67] 1.76908767 -1.29574792 -2.33015183 1.34381173 -4.76142574  
4.76765130

[73] -2.57316748 3.08834180 -6.91909955 2.11201548 -5.85359835  
5.31999481

[79] 1.63362138 0.76354026 -1.08657746 0.82812383 -2.11300976 -  
4.77740500

[85] 0.82282146 2.01405107 -1.04835503 -10.19971219 -7.34278473  
2.50825800

[91] 0.46737282 5.25361579 5.11304287 6.22146441 4.26909627  
1.34718265

[97] -0.28041149 -8.97408530 0.53684502 4.05240059 -1.01092313  
2.48307451

[103] 3.14561996 -2.33804904 -0.16113297 -4.07351885 0.79017924  
 2.81795893  
 [109] 8.24590961 -0.29762550 3.96982313 -11.50674955 10.23439042  
 9.90551785  
 [115] 10.57112242 6.82218095 6.82054890 2.33612755 -4.68330605  
 0.11914172  
 [121] 14.23579875 11.37839748 9.27069683 9.03464016 -13.79210026 -  
 0.59143364  
 [127] 20.21622127 10.80203742 6.01777544 14.79856446 6.64207002 -  
 0.29306223  
 [133] -13.55438295 1.82371468 -3.05055197 11.40399194 5.47932703  
 9.35328300  
 [139] 5.45751066 -3.66508118 -2.22868476 14.44522805 6.92117458  
 5.79601379  
 [145] 2.67099967 7.66165032 -20.77957883 -4.34628298 0.66846516 -  
 4.23067927  
 [151] -3.04718724 -6.85100224 -27.79434679 2.13337034 -13.36618043 -  
 31.14058777  
 [157] 26.32744749 8.23275547 -3.40384669 -3.59094418 -32.86258486  
 15.39028348  
 [163] -12.58878516 0.16010245 -6.38177495 -6.38689137 -18.65615208  
 13.70501236  
 [169] -14.73193693 5.56477104 -4.50400901 -0.22277377 -6.22618154 -  
 15.65213812  
 [175] 4.91527911 0.52569320 -2.85991208 -1.35929835 0.81072674 -  
 2.03544455  
 [181] -12.20393457 -2.91596638 2.77644461 -2.53144001 4.10450138 -  
 0.53490565

```

[187] -2.25892687 -6.21464720 -3.13155386 3.68822735 -2.24693717
1.67847711
[193] -4.01046595 -0.84551008 -4.85557121 -0.12895059 4.94232962 -
2.31692176
[199] -2.06876660
> residual_4=resid(dugaan4)
> residual_4
Time Series:
Start = 1
End = 199
Frequency = 1
[1] 0.03801313 -17.78226206 18.71851047 17.35538411 1.58658399 -
2.88922917
[7] -22.50125084 -6.72824422 11.79752780 4.64393554 1.22939409
4.41186962
[13] 0.72774460 -21.38310319 7.30242141 11.19335674 -8.63073834
2.82403435
[19] 4.53031476 0.21280264 -12.96626037 8.48134405 5.24527471 -
10.59676345
[25] -0.96293361 -3.37931877 1.46008931 -2.00710003 5.13911128 -
1.56027943
[31] 5.74492967 2.72786100 3.73176016 -4.52358066 -12.52686874
6.21935624
[37] 7.34059097 -4.07793260 -9.24417544 -1.05537776 -1.83102344 -
14.22264280
[43] 12.80582733 10.75855109 0.35059167 -13.04859345 -0.49125985 -
2.07358360
[49] -7.07486422 6.86230246 12.39264064 -0.37514840 -1.61394575
0.67561693

```

[55] -3.95285523 -0.43971303 -2.78005502 9.81623776 -1.85109353 -  
 0.68933122  
 [61] -4.53370117 2.31655631 -2.41070468 -4.17903404 10.09570940 -  
 2.43117926  
 [67] -1.42540282 -0.06427156 -2.62207427 2.13687309 -4.11327172  
 4.58481201  
 [73] -1.42817626 1.31154556 -6.16866549 1.84360189 -3.45783306  
 4.79284673  
 [79] 2.94616815 -1.78722826 -1.57674925 1.10070882 -1.66975179 -  
 4.88001624  
 [85] 2.19015199 3.48805263 -2.13398312 -10.96366848 -5.49472965  
 7.09393085  
 [91] 1.82922065 3.10789855 4.16493051 3.86819991 2.16684426 -  
 0.69048093  
 [97] -1.16203759 -8.72452579 2.06967060 7.27111490 -2.53373813  
 0.74167510  
 [103] 3.60549926 -3.50819373 -0.83610549 -2.79708091 1.28899498  
 4.06146809  
 [109] 7.23619875 -2.45321806 1.32415258 -10.98814410 10.58933557  
 13.16286189  
 [115] 4.81215828 2.31343931 3.58779283 0.50244325 -6.27896590  
 0.81175180  
 [121] 16.46870342 9.28805110 2.51592238 5.10075026 -16.48965902 -  
 0.75580312  
 [127] 26.56206139 7.74180028 -3.34880154 11.98087006 4.66380314 -  
 5.35827894  
 [133] -14.26369766 4.93144477 1.93022360 9.86300268 4.67834729  
 4.37724482

[139] 3.22711415 -6.63753905 -2.62369065 17.00890055 5.90305886 -  
 0.65452198  
 [145] 0.67276062 6.59847947 -21.80219370 -4.04563368 9.54056281 -  
 4.25811086  
 [151] -4.21134841 -5.10749425 -26.21126159 7.50763202 -4.36343483 -  
 33.16612946  
 [157] 33.75677415 15.15775743 -17.43717068 -5.30321364 -29.12289951  
 20.79664948  
 [163] -3.09138793 -7.05004877 -2.09227199 -6.04645359 -16.18764424  
 17.71223873  
 [169] -10.56665321 0.38382919 0.45840573 -2.34444827 -4.80101924 -  
 14.94537216  
 [175] 8.82757976 5.00086346 -6.44311584 -1.53524908 2.30413108 -  
 1.87837604  
 [181] -12.51621111 -0.68622364 7.39582074 -3.03442818 2.53197522 -  
 0.01308275  
 [187] -3.76900702 -5.49742101 -1.40076372 6.08211523 -2.24676063  
 0.02220959  
 [193] -3.22299895 -0.98351370 -3.26258395 0.48606499 6.43410762 -  
 3.35942932  
 [199] -3.82694712

```
> residual_5=resid(dugaan5)
```

```
> residual_5
```

Time Series:

Start = 1

End = 199

Frequency = 1

[1] 0.03801313 -17.08336702 17.55233340 16.21147152 6.46683896  
 1.43440243  
 [7] -20.59821692 -8.93687582 6.68213689 3.27232036 2.66487391  
 5.53119364  
 [13] 2.07627319 -19.95273512 5.22482915 8.07652876 -7.04809231  
 3.53193323  
 [19] 3.84079181 1.25480301 -11.98385830 7.25105097 3.91827776 -  
 8.96936167  
 [25] -1.23918214 -5.16766382 0.32435847 -3.02842519 4.66310715 -  
 1.54374431  
 [31] 6.36931457 3.37670555 5.39047120 -2.99684655 -11.76747687  
 4.23534771  
 [37] 5.55521520 -2.82874016 -8.46979552 -2.57251353 -3.86944457 -  
 15.45600123  
 [43] 9.91940297 8.95162820 3.05186694 -10.70639412 -1.05649194 -  
 4.18335339  
 [49] -8.09048013 4.92070681 11.35451738 1.85858979 0.93511983  
 1.46226039  
 [55] -3.49118930 -0.58088590 -3.49355527 9.15886612 -1.34748783  
 0.82105941  
 [61] -4.46608237 1.88153568 -3.01046507 -4.32161755 8.97357379 -  
 2.15959641  
 [67] -0.08539707 -0.28242915 -2.70305688 1.71956454 -4.41982078  
 4.26600045  
 [73] -1.68987962 1.80984901 -6.16385574 1.35145799 -4.43572936  
 4.31875540  
 [79] 2.66825821 -0.70664216 -1.05578205 0.90451289 -1.76310952 -  
 4.96469110

[85] 1.21167934 2.64037004 -1.68206485 -10.65873848 -7.15912674  
 4.04330033  
 [91] 0.69493803 3.76708343 4.87147698 5.27080997 3.90897589  
 0.98717904  
 [97] -0.11956678 -8.42883659 0.97504689 5.76342595 -1.79813598  
 1.62161461  
 [103] 3.61631193 -2.74238285 -0.45709298 -3.29344765 0.70840987  
 3.49552921  
 [109] 7.74874233 -0.74447032 2.82229317 -10.55126007 9.75421353  
 12.47168762  
 [115] 8.09487568 6.02073495 6.30183565 2.75604192 -4.50379508  
 0.93825494  
 [121] 15.81138592 11.45442434 7.11173300 8.67022949 -13.61820445 -  
 0.64078247  
 [127] 24.08056254 10.48056299 2.65813518 14.97513597 7.50300614 -  
 1.34380140  
 [133] -12.58598941 3.25256406 -0.08981658 10.16250310 6.04264724  
 7.15333347  
 [139] 5.60508161 -4.31931917 -1.89706264 16.08878116 7.56940967  
 3.41225690  
 [145] 2.99665333 7.90281704 -20.05770763 -5.06393051 5.18634969 -  
 5.04131010  
 [151] -4.06060532 -6.51644530 -27.97496821 2.43097745 -9.66283085 -  
 34.70509149  
 [157] 27.26424389 11.75757035 -11.50237777 -3.96072300 -31.50685531  
 15.62533402  
 [163] -7.28773320 -5.79410454 -3.98300069 -7.84604000 -18.16424194  
 13.66672960



```

[169] -12.51068959  0.89886711 -1.57135021 -2.65859231 -5.47130760 -
16.22604598
[175]  5.54962823  2.42964291 -5.47655327 -1.70088487  1.08799691 -
2.19544837
[181] -12.65475414 -2.76304587  4.51768074 -3.30488781  2.86060535 -
0.17790645
[187] -3.30741991 -5.90485761 -2.81911604  4.47839551 -2.36531751
0.48776674
[193] -3.51656322 -1.39961017 -4.12463999 -0.41905829  5.52964712 -
2.82253956
[199] -3.14962748

```

```
> residual_6=resid(dugaan6)
```

```
> residual_6
```

Time Series:

Start = 1

End = 199

Frequency = 1

```

[1]  0.03801313 -17.07362658  18.18411262  13.64905479  8.44669655
0.81774139
[7] -19.90629215 -8.55331163  5.30344500  3.27191071  3.04663461
5.45821103
[13]  2.07640491 -19.68830551  6.05449748  5.87451275 -5.54343514
3.42828881
[19]  3.30221587  1.67192873 -12.06065155  7.92058321  2.29010943 -
7.53507205
[25] -1.52487030 -5.52303519  0.70740861 -3.62108615  5.27419555 -
2.33528303

```

[31] 7.33690338 2.33732594 6.38414341 -3.71438316 -10.81044529  
3.85034529

[37] 4.78883215 -2.26492170 -8.30834687 -2.48163200 -4.40444848 -  
15.06885107

[43] 10.14601018 7.36273546 4.49212609 -11.14075381 -0.05580680 -  
5.60069495

[49] -7.01831497 4.29403792 11.06283495 1.93107277 1.62815244  
1.06309874

[55] -3.27846500 -0.52568797 -3.77803889 9.45211695 -2.19783462  
2.10058849

[61] -5.47346922 2.80590054 -4.05905407 -3.33669431 8.29625754 -  
2.37843977

[67] 0.79009769 -1.00932997 -2.21520253 1.47447129 -4.51146932  
4.64928423

[73] -2.43324739 2.69735337 -6.95855295 2.30061704 -5.57112970  
5.40266020

[79] 1.44829244 0.33119450 -1.54168936 1.23568833 -2.12515738 -  
4.57955504

[85] 1.05039772 2.36388711 -1.51317830 -10.49048058 -6.89360897  
3.46445088

[91] 0.45483939 4.24980585 4.49050034 5.59613472 3.77426581  
1.23257758

[97] -0.12189396 -8.41845837 1.28227611 4.89915121 -1.40325662  
1.84906410

[103] 3.27549472 -2.58035444 -0.21148715 -3.64486135 1.04724841  
3.00479549

[109] 7.98711928 -1.00780980 3.56353755 -11.27222735 10.86943315  
10.50855396

[115] 9.53090029 5.51445111 6.87765295 2.36591212 -4.05256896  
 0.90120593  
 [121] 15.39017984 11.02383460 7.93146276 8.50749242 -13.53887838  
 0.35891776  
 [127] 22.36324475 10.43509155 3.83130532 14.71771601 7.03332876 -  
 0.50863201  
 [133] -12.73465693 3.67540738 -1.51156337 11.31826081 4.79729017  
 8.43495977  
 [139] 4.78060179 -3.58658552 -1.92102941 15.80591707 6.82819209  
 4.63809354  
 [145] 2.46921135 8.25801353 -20.57532038 -3.35378652 2.80091203 -  
 4.01111603  
 [151] -4.13108392 -6.55034038 -27.90243126 3.25626615 -12.16544832 -  
 32.25133894  
 [157] 26.68509506 8.73289130 -7.92734645 -4.90297787 -31.43889167  
 16.68589057  
 [163] -10.82372370 -1.86761550 -6.75720748 -6.06291729 -19.24826866  
 14.79867302  
 [169] -15.05755786 4.27032600 -4.65912024 -0.33516183 -6.99836019 -  
 15.04375457  
 [175] 5.13433130 1.42437864 -4.43688925 -1.89300698 0.97923363 -  
 2.26343996  
 [181] -12.39569369 -2.48410267 3.61818195 -3.02962842 3.21224795 -  
 0.70765061  
 [187] -2.71671116 -6.15624235 -2.59753890 4.06039492 -2.43864539  
 0.99762443  
 [193] -4.01190442 -0.85640089 -4.66345628 0.06033009 4.96374886 -  
 2.67765003  
 [199] -2.71297681

```
> residual_7=resid(dugaan7)
```

```
> residual_7
```

```
Time Series:
```

```
Start = 1
```

```
End = 199
```

```
Frequency = 1
```

```
[1]      0.038013131 -16.422128738   17.558818309   12.848247548  
7.892654164  3.209006507
```

```
[7] -19.141468670 -8.761382711  2.750721007  0.422316047  2.123312442  
5.391335746
```

```
[13]   2.595867083 -18.626947419   5.393702531   5.160716553  -  
6.428647389  4.540728417
```

```
[19]  3.474226930  2.433102196 -10.745161253  7.719848705  2.588206805  
-7.734201596
```

```
[25]   -0.761731466   -6.348523792   -0.220632302   -4.047537189  
4.631497610 -1.501344114
```

```
[31]  7.817879067  4.484681271  7.843744392 -0.883534286 -9.773372721  
4.022013860
```

```
[37]   3.670059364  -2.781841246  -8.308052118  -3.681963180  -  
5.972359379 -16.912371630
```

```
[43]  8.052558690  6.501455297  5.121062322 -7.725112337  1.416428465  
-3.820710170
```

```
[49] -6.950407929  5.152130841 11.394820612  4.252480033  4.592429376  
3.967349015
```

```
[55] -1.563855346  0.492492973 -3.798431201  8.525486567 -2.401029129  
1.331515594
```

```
[61] -5.394855226  0.984725506 -4.819410034 -5.380607254  7.184043919  
-3.510983269
```

[67] 0.568661451 -0.750887236 -2.692936839 1.548144836 -4.745595424  
4.438134502

[73] -2.068820183 2.690874776 -5.925832007 1.929374268 -4.972778079  
4.648065946

[79] 2.425837339 0.557233576 0.063062171 1.590125428 -1.303753659  
-4.503077946

[85] 0.982361646 1.916149429 -1.496916480 -10.204850921 -  
7.540992912 2.161232174

[91] -0.479809739 4.575305775 6.090898282 7.608180548 6.721266069  
3.889668350

[97] 2.167608233 -7.254191844 0.848570940 3.798277347 -2.736841078  
1.158501164

[103] 2.332316511 -3.457972124 -1.062617323 -4.740846417 -  
0.594698291 1.864868302

[109] 7.023267701 -0.505150824 3.917659494 -10.447841700  
9.721392076 10.653362687

[115] 9.382897105 7.987791424 7.903917489 3.604014436 -4.498222604  
-0.754351841

[121] 12.191577186 8.445205811 6.276829810 7.489821261 -  
15.403024964 -3.536731439

[127] 17.324702064 5.853798494 1.810081127 12.922533405  
4.864514456 -2.734473990

[133] -15.632495894 -2.142157626 -7.657902936 4.544342324  
0.894800807 4.617053662

[139] 3.549531324 -5.431438550 -3.273631169 13.228972056  
5.484821832 4.092127485

[145] 2.851674410 7.127064629 -21.264064296 -6.960355913 -  
1.222054338 -9.498672026

```

[151] -7.003850785 -9.886945750 -30.575994069 -0.758969972 -
14.641112691 -34.640707609
[157] 26.112941253 10.257999967 -2.506407096 4.400847426 -
25.296046440 20.915700137
[163] -5.824724113 1.557647633 0.128942745 -3.408786461 -
14.360546162 16.081565578
[169] -11.177174896 6.118339444 0.420574917 1.303703101 -
2.233926500 -13.307138664
[175] 7.152803536 2.569538478 -2.302931988 1.142255490 3.105603513
0.168572804
[181] -10.153034954 -1.300189951 4.228453373 -2.230156545
4.972997258 1.363607618
[187] -0.856760064 -4.112835032 -1.831767031 4.698905591 -
1.698784862 2.114225568
[193] -2.657723454 -0.300691857 -3.780276931 -0.004481036
5.510647553 -2.025217899
[199] -1.516051658

```

```
> residual_8=resid(dugaan8)
```

```
> residual_8
```

```
Time Series:
```

```
Start = 1
```

```
End = 199
```

```
Frequency = 1
```

```

[1] 0.03801313 -16.99377117 17.95354175 13.84205333 9.78061163 -
0.07849919
[7] -23.14229560 -9.32594487 5.26968312 5.65516371 4.85619203
4.78916915

```

[13] 1.35823188 -20.19135900 5.31928682 6.01366627 -3.87641489  
3.97343901

[19] 1.82577308 2.28573037 -12.22941311 7.20582805 2.47443371 -  
6.74370684

[25] -1.48880179 -6.48030639 1.84085523 -3.01423953 5.71701922 -  
1.90112789

[31] 7.25942221 2.28328112 5.82777554 -4.03334773 -11.94601589  
3.60790172

[37] 4.92113144 -0.83305059 -8.39408395 -3.33497831 -3.99125122 -  
14.02800352

[43] 10.97682942 8.15247349 5.92345509 -11.51315134 -1.97956762 -  
5.57238875

[49] -6.31748819 5.39904093 11.30971957 3.08223662 1.00441065 -  
0.38550751

[55] -4.05112297 -0.54530623 -3.97172508 9.81466546 -1.84378180  
2.09658682

[61] -6.01049913 2.17795755 -3.53027861 -3.34381952 8.75537595 -  
2.40565209

[67] 1.38905459 -1.78713517 -2.52240741 1.86198826 -4.63220510  
5.03430088

[73] -2.40907704 2.86900321 -6.96689064 1.95556543 -5.18629312  
5.58472470

[79] 2.07392157 0.17401028 -1.45233948 0.39053456 -1.82900627 -  
4.64342915

[85] 1.19739433 2.51797118 -0.87735737 -10.48828712 -7.22219906  
3.86614991

[91] 1.78648484 5.40752116 4.26891639 5.12601819 3.35953493  
0.28745029

[97] -0.87332166 -9.12074711 1.09559811 5.13079807 -0.62692387  
2.11729205

[103] 2.48280105 -2.62911341 -0.32643826 -4.07961207 1.19507976  
3.36132628

[109] 8.18792247 -0.90818711 2.80813144 -12.07027192 10.37982527  
10.83670047

[115] 9.83910321 5.12199959 4.36168910 1.26501250 -5.39479084  
0.15080371

[121] 14.85783792 11.44178882 7.58957276 6.53481336 -15.74088755 -  
0.86964947

[127] 21.58228641 11.33250944 4.17772702 11.68908750 4.77571451 -  
1.39647433

[133] -14.54875480 2.18846747 -1.08033249 12.44039641 5.30572272  
7.54501606

[139] 4.02659375 -5.29424429 -2.63948372 14.79629899 7.25796293  
4.53832369

[145] 0.78200808 6.42585392 -20.98122638 -4.18756370 2.69265888 -  
2.53598400

[151] -2.24509984 -7.35515272 -27.21783979 4.03910311 -10.51534845 -  
29.38283336

[157] 28.43340486 9.74185506 -4.32831838 -6.30357164 -34.50259922  
18.37291274

[163] -9.30158416 0.84969518 -6.06892442 -7.11178225 -17.00438931  
14.76227233

[169] -12.99522549 5.54678505 -4.27832487 -0.72430376 -5.36566088 -  
15.88598935

[175] 6.39630423 2.02318012 -2.44306801 -1.82394047 0.32763112 -  
1.53019746



```

[181] -12.09324590 -2.45381760  4.12654205 -1.59492752  4.04670713 -
1.17567729
[187] -2.65029936 -6.17055733 -2.79515744  4.74316490 -1.73164732
1.49610190
[193] -4.35162341 -0.90389068 -4.33907130  0.24424341  5.57116262 -
2.39500070
[199] -2.48178483

```

```
> residual_9=resid(dugaan9)
```

```
> residual_9
```

```
Time Series:
```

```
Start = 1
```

```
End = 199
```

```
Frequency = 1
```

```

[1]  0.03801313 -16.93978231  17.91438259  13.82218454  8.72212553
2.70556992
[7] -21.02239747 -9.45909707  4.13729683  3.02368677  4.28158417
6.02369008
[13]  2.12993662 -19.64630542  5.30975564  5.62564739 -5.80718974
4.75216278
[19]  2.75751913  1.68948252 -11.66061842  7.30145898  2.38194296 -
7.79294548
[25] -0.74086549 -6.34191343  0.54576997 -3.29574014  5.12366635 -
1.71825160
[31]  7.10134847  3.03035497  5.98505707 -3.02900252 -11.53149562
3.63317366
[37]  4.18622919 -1.90704132 -7.70502411 -2.98988273 -4.73093716 -
15.23920206

```

[43] 10.12924543 7.61732301 4.91060231 -9.74723043 -1.09516871 -  
5.73189041

[49] -7.85114798 4.88596708 10.80095995 2.79438652 2.16789487  
1.07617154

[55] -3.86709947 -0.64684492 -4.03614164 9.22292107 -1.73444262  
2.00179052

[61] -4.93463862 1.86537223 -3.59640494 -3.91776900 8.74873053 -  
2.58380378

[67] 1.16716987 -0.76909761 -2.80490781 1.70583108 -4.71307091  
4.64206237

[73] -2.19948920 2.47286474 -6.44197615 1.62924137 -5.15908703  
4.77234560

[79] 2.25720170 -0.04779875 -0.83329161 0.64753680 -1.96462342 -  
4.82436669

[85] 1.07579573 2.18221453 -1.30389746 -10.24900351 -7.27693227  
3.06036961

[91] 0.44738180 4.86460460 5.06645247 5.59228391 4.14109840  
1.11390386

[97] -0.19483907 -8.76971283 0.79938431 4.76136134 -1.41301022  
2.43248073

[103] 3.20513900 -2.68470279 -0.13872777 -3.79924491 0.70524504  
3.19563344

[109] 7.96300476 -0.41118684 3.48595287 -11.14321822 9.94034660  
11.01481607

[115] 9.31627627 6.98714490 6.26177737 2.42254476 -4.64528786  
0.59261396

[121] 14.84388187 11.31895511 8.57552590 8.96968135 -14.05956246 -  
0.48612204

[127] 21.79793346 10.28717774 5.24527576 14.96400363 6.36614442 -  
0.67121734

[133] -12.88270724 2.30845220 -1.85862431 10.94564175 6.05970603  
8.16605674

[139] 5.64969436 -4.26416028 -1.93654620 15.03552275 7.03856262  
5.05011399

[145] 3.00241715 7.37141438 -20.46859933 -4.42075151 2.59037361 -  
4.98617038

[151] -2.73429236 -6.85943758 -28.05877584 2.48994823 -12.06080365 -  
32.66954028

[157] 27.61474698 8.65123294 -6.71813518 -2.66510588 -33.50241461  
15.69645515

[163] -10.41336967 -2.35705103 -4.35895244 -8.04839061 -17.98176824  
13.57040522

[169] -13.94065788 3.70795349 -2.82674432 -2.04605458 -5.31471701 -  
16.23043661

[175] 5.43416100 1.07683088 -3.92252595 -1.04879359 0.51943949 -  
2.16189261

[181] -12.28209105 -2.75095163 3.37874609 -2.95742953 3.92961497 -  
0.50510158

[187] -2.87502045 -5.93193191 -3.12038749 4.05360732 -2.33182915  
1.34384410

[193] -3.79964117 -1.24579571 -4.44735745 -0.32973374 5.29047043 -  
2.64670850

[199] -2.35528825

```
> residual_10=resid(dugaan10)
```

```
> residual_10
```

Time Series:

Start = 1

End = 199

Frequency = 1

[1] 0.03801313 -16.41285662 17.61969743 12.75649804 6.89241682  
4.64857926

[7] -17.69711135 -8.67587078 1.68318517 -2.04835884 1.17207269  
6.98358293

[13] 5.24701240 -16.06851514 7.19403887 5.66725540 -8.26949400  
3.71491919

[19] 3.12477777 1.46708386 -11.10250980 7.45671051 2.28983384 -  
8.84735418

[25] -0.60703634 -5.99559566 -0.38621126 -3.58756756 5.18151708 -  
0.39743373

[31] 8.61083645 5.25665002 7.39436770 -1.91336947 -11.93568274  
1.46889659

[37] 0.81226779 -5.29939338 -8.46017148 -2.13931691 -3.82474052 -  
14.71282784

[43] 10.69290495 9.03600233 6.45034623 -5.87112034 1.94508782 -  
5.23687933

[49] -10.66787471 1.52371841 8.30632281 2.18017483 4.41085757  
4.79723368

[55] -1.56595096 -0.47570519 -5.48099319 6.40825096 -3.83352857  
0.66313938

[61] -4.25536347 2.28817096 -3.06891070 -3.94318253 8.93367097 -  
2.18551822

[67] 1.48573143 0.55912366 -2.50761204 1.26989332 -5.41739855  
3.56703256

[73] -2.48150769 2.20895203 -5.63966286 1.99674445 -4.70453331  
4.34335762

[79] 2.52913483 0.28818793 0.20365479 1.41910532 -1.99950925 -  
5.52200021

[85] 0.08224405 1.17627966 -1.97107379 -9.82571499 -6.63750535  
3.08141362

[91] -0.01018031 5.26151671 7.42350091 8.34089738 6.60294295  
2.45882454

[97] -0.53966698 -10.88358552 -2.98000809 0.86456605 -4.47619805  
1.94283420

[103] 5.16020738 -0.19672482 2.22259641 -2.12996988 0.57026233  
2.18677528

[109] 6.60717475 -0.87535173 3.70296932 -10.41025700 9.14303138  
10.25073834

[115] 8.24514371 8.16583053 8.27265948 3.29179209 -5.69131074 -  
2.33236623

[121] 10.76497636 7.64771282 7.20913397 10.64830847 -11.86014240 -  
0.55602941

[127] 19.86010336 6.75299345 3.44986780 16.42059543 7.66707807 -  
1.18916924

[133] -14.27834214 -1.53949449 -7.16689837 5.53560555 4.66410328  
9.90284197

[139] 10.07517290 0.02648089 0.29245416 14.42603234 4.24071745  
1.91404245

[145] 1.67462868 5.96744626 -22.13753272 -7.17782073 0.08364530 -  
8.40405539

[151] -3.59366409 -4.48337839 -25.16319921 4.23705894 -10.70131004 -  
33.13848224

[157] 28.51922194 11.47665941 -3.99222882 4.81512012 -27.74260195  
14.50395444

```

[163] -13.72692203 -8.19471268 -5.32883280 -7.78653846 -16.62951055
15.32017723
[169] -11.19166280 5.64109580 1.57698228 0.20682352 -3.75648247 -
16.06475812
[175] 3.80453482 -0.83883722 -5.69376755 0.05930290 2.86332298 -
0.19631543
[181] -10.60082100 -1.99563945 3.04360589 -4.18718755 3.73585787
0.97884673
[187] -1.51050803 -4.61912226 -2.83745844 3.28115563 -3.27746257
0.99841159
[193] -2.88793271 -0.62238868 -3.87857380 -0.37751283 5.27075755 -
2.39766101
[199] -1.68507918

```

```
> residual_11=resid(dugaan11)
```

```
> residual_11
```

Time Series:

Start = 1

End = 199

Frequency = 1

```

[1] 0.03801313 -16.14889138 17.20509964 12.44624219 9.81246333
2.61727653
[7] -19.11584143 -9.80331126 1.46072923 1.02291696 2.49749314
5.55361435
[13] 2.91735109 -18.46317831 4.94360077 4.25667834 -4.98766408
4.02709504
[19] 3.38236843 2.91034832 -10.94416155 7.55930823 1.94395283 -
6.69139337

```

[25] -1.50419147 -6.52300613 -0.04360487 -4.28435762 5.12254009 -  
1.64117261

[31] 8.46522885 4.13118749 8.50959467 -1.33908266 -9.63111583  
3.06902201

[37] 3.37007225 -2.18510626 -8.49948365 -3.89503523 -6.17725089 -  
16.53657558

[43] 7.89340832 6.53684094 6.76173683 -7.90117226 1.56758364 -  
4.69361350

[49] -6.47638152 4.40906272 11.51881499 4.78767249 4.75538864  
3.49045871

[55] -1.67888323 0.07398329 -4.20827407 8.49012796 -2.54822342  
2.03474205

[61] -6.00421809 1.49518767 -5.21832311 -4.71710236 6.82982715 -  
2.98008719

[67] 1.16742854 -1.17198098 -2.24157243 1.26822447 -4.67627114  
4.48531579

[73] -2.35321661 3.14219990 -6.44927646 2.20067518 -5.63011046  
5.13317395

[79] 1.88717530 1.28014506 -0.36106065 1.65519833 -1.50515158 -  
4.45258175

[85] 0.68645163 1.85956380 -1.18241285 -10.18494484 -7.72520764  
1.77636260

[91] -0.06851348 5.12842221 6.15717884 8.07828150 6.70508961  
3.91845960

[97] 1.82827771 -7.64806072 0.37662660 3.19374679 -2.25485338  
1.12858592

[103] 2.24505317 -3.09045790 -1.00549627 -4.84146468 -0.35226664  
1.78049754

[109] 7.50823748 -0.27837642 4.25033227 -10.87950017 9.83857292  
 9.84778017  
 [115] 10.65978177 7.56544648 8.01485231 3.13275052 -4.72013557 -  
 1.41023464  
 [121] 11.69094220 8.75873971 6.94184786 7.33166756 -15.30011895 -  
 3.80550565  
 [127] 16.25765568 7.06795030 2.70399466 12.53739048 5.03424546 -  
 2.37570574  
 [133] -16.30911415 -2.68455898 -8.35866974 5.37241465 0.67735915  
 5.74536627  
 [139] 3.28672493 -4.91410202 -3.71456318 12.74638244 5.59776061  
 4.66626740  
 [145] 2.10835081 6.97450655 -21.75090073 -7.27633618 -2.92375885 -  
 8.38811792  
 [151] -7.13453962 -9.77546843 -30.28448948 -0.95142610 -15.10451684 -  
 32.73730729  
 [157] 24.96942917 10.69980333 0.60726582 2.86807436 -25.47000570  
 19.92559609  
 [163] -7.43068962 3.48177906 -2.33861119 -2.48352300 -15.48742355  
 16.02661900  
 [169] -11.71281782 7.75451134 -1.16081600 3.01658875 -3.05317098 -  
 12.60938162  
 [175] 6.62219723 2.61300981 -1.07731775 0.87556308 3.33797857  
 0.37032422  
 [181] -9.97749853 -1.54239390 3.85280515 -1.55800723 5.15448610  
 1.30324154  
 [187] -0.40808710 -4.44392483 -1.88248884 4.43800801 -1.42962901  
 2.36495351



```
[193] -2.91511260 -0.02952058 -4.11834739 0.23685542 5.28736840 -
1.57170387
```

```
[199] -1.35170600
```

- Hasil Uji White Noise

Model 1 ARIMA (0,1,1)

```
> Box.test(residual_1,type="Ljung")
```

Box-Ljung test

```
data: residual_1
```

```
X-squared = 0.53278, df = 1, p-value = 0.4654
```

Karena p-value > 0,05 maka residualnya tidak white noise

Model 2 ARIMA (0,1,2)

```
> Box.test(residual_2,type="Ljung")
```

Box-Ljung test

```
data: residual_2
```

```
X-squared = 0.054511, df = 1, p-value = 0.8154
```

Karena p-value > 0,05 maka residualnya tidak white noise

Model 3 ARIMA (0,1,3)

```
> Box.test(residual_3, type="Ljung")
```

Box-Ljung test

```
data: residual_3
```

X-squared = 0.011112, df = 1, p-value = 0.916

Karena p-value > 0,05 maka residualnya tidak white noise

Model 4 ARIMA (1,1,0)

```
> Box.test(residual_4,type="Ljung")
```

Box-Ljung test

data: residual\_4

X-squared = 1.4901, df = 1, p-value = 0.2222

Karena p-value > 0,05 maka residualnya tidak white noise

Model 5 ARIMA (1,1,1)

```
> Box.test(residual_5,type="Ljung")
```

Box-Ljung test

data: residual\_5

X-squared = 0.028862, df = 1, p-value = 0.8651

Karena p-value > 0,05 maka residualnya tidak white noise

Model 6 ARIMA (1,1,2)

```
> Box.test(residual_6,type="Ljung")
```

Box-Ljung test

data: residual\_6

X-squared = 0.069819, df = 1, p-value = 0.7916

Karena p-value > 0,05 maka residualnya tidak white noise

Model 7 ARIMA (1,1,3)

```
> Box.test(residual_7, type="Ljung")
```

Box-Ljung test

data: residual\_7

X-squared = 0.0529, df = 1, p-value = 0.8181

Karena p-value > 0,05 maka residualnya tidak white noise

Model 8 ARIMA (2,1,0)

```
> Box.test(residual_8,type="Ljung")
```

Box-Ljung test

data: residual\_8

X-squared = 0.020156, df = 1, p-value = 0.8871

Karena p-value > 0,05 maka residualnya tidak white noise

Model 9 ARIMA (2,1,1)

```
> Box.test(residual_9,type="Ljung")
```

Box-Ljung test

data: residual\_9

X-squared = 0.0034388, df = 1, p-value = 0.9532

Karena p-value > 0,05 maka residualnya tidak white noise

Model 10 ARIMA (2,1,2)

```
> Box.test(residual_10,type="Ljung")
```

Box-Ljung test

data: residual\_10

X-squared = 0.068342, df = 1, p-value = 0.7938

Karena p-value > 0,05 maka residualnya tidak white noise

Model 11 ARIMA (2,1,3)

```
> Box.test(residual_11,type="Ljung")
```

Box-Ljung test

data: residual\_11

X-squared = 0.0025115, df = 1, p-value = 0.96

Karena p-value > 0,05 maka residualnya tidak white noise

- Hasil Uji Normalitas

#Model 1 ARIMA (0,1,1)

```
> ks.test(residual_1,"pnorm", mean(residual_1),sd(residual_1))
```

One-sample Kolmogorov-Smirnov test

data: residual\_1

D = 0.099253, p-value = 0.03965

alternative hypothesis: two-sided

Karena p-value < 0,05 maka data tidak berdistribusi normal

Model 2 ARIMA (0,1,2)

```
> ks.test(residual_2,"pnorm", mean(residual_2),sd(residual_2))
```

One-sample Kolmogorov-Smirnov test

data: residual\_2

D = 0.09865, p-value = 0.04158

alternative hypothesis: two-sided

Karena p-value < 0,05 maka data tidak berdistribusi normal

Model 3 ARIMA (0,1,3)

```
> ks.test(residual_3,"pnorm", mean(residual_3),sd(residual_3))
```

One-sample Kolmogorov-Smirnov test

data: residual\_3

D = 0.094482, p-value = 0.05728

alternative hypothesis: two-sided

Karena p-value > 0,05 maka data berdistribusi normal

Model 4 ARIMA (1,1,0)

```
> ks.test(residual_4,"pnorm", mean(residual_4),sd(residual_4))
```

One-sample Kolmogorov-Smirnov test

data: residual\_4

D = 0.11129, p-value = 0.01446

alternative hypothesis: two-sided

Karena p-value < 0,05 maka data tidak berdistribusi normal

Model 5 ARIMA (1,1,1)

```
> ks.test(residual_5,"pnorm", mean(residual_5),sd(residual_5))
```

One-sample Kolmogorov-Smirnov test

data: residual\_5

D = 0.10185, p-value = 0.03221

alternative hypothesis: two-sided

Karena p-value < 0,05 maka data tidak berdistribusi normal

Model 6 ARIMA (1,1,2)

```
> ks.test(residual_6,"pnorm", mean(residual_6),sd(residual_6))
```

One-sample Kolmogorov-Smirnov test

data: residual\_6

D = 0.093295, p-value = 0.0626

alternative hypothesis: two-sided

Karena p-value > 0,05 maka data berdistribusi normal

Model 7 ARIMA (1,1,3)

```
> ks.test(residual_7,"pnorm", mean(residual_7),sd(residual_7))
```

One-sample Kolmogorov-Smirnov test

data: residual\_7

D = 0.087741, p-value = 0.09339

alternative hypothesis: two-sided

Karena  $p\text{-value} > 0,05$  maka data berdistribusi normal

Model 8 ARIMA (2,1,0)

```
> ks.test(residual_8,"pnorm", mean(residual_8),sd(residual_8))
```

One-sample Kolmogorov-Smirnov test

data: residual\_8

D = 0.096278, p-value = 0.04998

alternative hypothesis: two-sided

Karena  $p\text{-value} < 0,05$  maka data tidak berdistribusi normal

Model 9 ARIMA (2,1,1)

```
> ks.test(residual_9,"pnorm", mean(residual_9),sd(residual_9))
```

One-sample Kolmogorov-Smirnov test

data: residual\_9

D = 0.095469, p-value = 0.05317

alternative hypothesis: two-sided

Karena  $p\text{-value} > 0,05$  maka data berdistribusi normal

Model 10 ARIMA (2,1,2)

```
> ks.test(residual_10,"pnorm", mean(residual_10),sd(residual_10))
```

One-sample Kolmogorov-Smirnov test

data: residual\_10

D = 0.074857, p-value = 0.2147

alternative hypothesis: two-sided

Karena  $p\text{-value} > 0,05$  maka data berdistribusi normal

Model 11 ARIMA (2,1,3)

```
> ks.test(residual_11,"pnorm", mean(residual_11),sd(residual_11))
```

One-sample Kolmogorov-Smirnov test

data: residual\_11


$D = 0.087973$ ,  $p\text{-value} = 0.09189$

alternative hypothesis: two-sided

Karena  $p\text{-value} > 0,05$  maka data berdistribusi normal

- Hasil Pemeriksaan Diagnostik

Model ARIMA 1 (1,1,0)





```
hasil_1=acfStat(dugaan1$residuals)
```


```
> hasil_1
```

	ACF	PACF	Q-Stats	P-Value
[1,]	1.0000000000	1.0000000000	NA	NA
[2,]	0.051355075	0.0513550748	0.5327834	<b>4.654390e-01</b>
[3,]	-0.131972567	-0.1349658617	4.0690926	<b>1.307398e-01</b>
[4,]	0.039001011	0.0547637446	4.3795091	<b>2.232929e-01</b>
[5,]	-0.079421775	-0.1055342732	5.6733882	<b>2.249037e-01</b>
[6,]	0.046562953	0.0743298122	6.1204097	<b>2.946783e-01</b>
[7,]	0.172043394	0.1401603940	12.2547495	<b>5.652106e-02</b>
[8,]	0.219943827	0.2383056501	22.3326823	<b>2.225629e-03</b>
[9,]	0.206539036	0.2409248031	31.2661498	<b>1.259734e-04</b>
[10,]	-0.052644522	0.0046989131	31.8495974	<b>2.114059e-04</b>
[11,]	-0.082906587	-0.0156723890	33.3042705	<b>2.420968e-04</b>
[12,]	0.002203773	-0.0192501256	33.3053038	<b>4.694405e-04</b>
[13,]	-0.006088148	-0.0495122170	33.3132321	<b>8.648137e-04</b>
[14,]	0.152739097	0.0586831781	38.3301458	<b>2.555742e-04</b>
[15,]	0.238111053	0.1281633883	50.5886228	<b>4.864556e-06</b>
[16,]	0.078856762	0.0517496717	51.9404127	5.778072e-06
[17,]	-0.016537902	0.0160758402	52.0001931	<b>1.095315e-05</b>
[18,]	-0.098731345	-0.0593684915	54.1425304	<b>9.400378e-06</b>
[19,]	0.050670514	0.0928224206	54.7099198	<b>1.421665e-05</b>
[20,]	-0.012405969	-0.0927009111	54.7441207	<b>2.543624e-05</b>
[21,]	0.028503501	-0.0503286773	54.9256691	<b>4.212487e-05</b>
[22,]	0.171740368	0.0002526202	61.5535381	<b>7.411217e-06</b>
[23,]	0.096285833	0.0318359274	63.6486182	<b>6.345649e-06</b>
[24,]	-0.096467571	-0.0731396870	65.7635636	<b>5.384440e-06</b>
[25,]	-0.110458460	-0.0871684754	68.5523102	<b>3.614648e-06</b>
[26,]	-0.068967855	-0.0842295879	69.6457461	<b>4.342916e-06</b>

[27,] -0.072624973 -0.1476467678 70.8652270 **4.960101e-06**  
 [28,] 0.086308446 0.0070084084 72.5975437 **4.742459e-06**  
 [29,] 0.180134320 0.0925285983 80.1876167 **6.258714e-07**  
 [30,] -0.064958691 -0.1120280492 81.1804463 **7.772037e-07**  
 [31,] -0.093826615 -0.0308300596 83.2640472 **6.635318e-07**  
 [32,] -0.061649227 0.0058614790 84.1689358 **8.392542e-07**  
 [33,] -0.088880069 -0.0176020961 86.0610242 **7.601809e-07**  
 [34,] -0.046403694 -0.0356975757 86.5798794 **1.078752e-06**  
 [35,] 0.001016543 -0.0632884534 86.5801299 **1.790576e-06**  
 [36,] 0.065153713 -0.0133496804 87.6154714 **2.109395e-06**  
 [37,] -0.014092689 -0.0745508310 87.6642074 **3.367979e-06**

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 2 ARIMA (0,1,2)




```
> hasil_2=acfStat(dugaan2$residuals)
```

```
> hasil_2
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 3 ARIMA (0,1,3)




```
> hasil_3=acfStat(dugaan3$residuals)
```

```
> hasil_3
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 4 ARIMA (1,1,0)




```
> hasil_4=acfStat(dugaan4$residuals)
```

```
> hasil_4
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 5 ARIMA (1,1,1)




```
> hasil_5=acfStat(dugaan5$residuals)
```

```
> hasil_5
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 6 ARIMA (1,1,2)




```
> hasil_6=acfStat(dugaan6$residuals)
```

```
> hasil_6
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 7 ARIMA (1,1,3)



```
> hasil_7=acfStat(dugaan7$residuals)
```

```
> hasil_7
```

```
> hasil_7=acfStat(dugaan7$residuals)
```

```
> hasil_7
```


	ACF	PACF	Q-Stats	P-Value
[1,]	1.000000000	1.000000000	NA	NA
[2,]	-0.016182207	-0.016182207	0.05290046	0.91809099
[3,]	-0.004880546	-0.005143757	0.05773684	0.97154429
[4,]	0.064967961	0.064824030	0.91911040	0.93481375
[5,]	-0.111005999	-0.109433165	3.44670500	0.48602810
[6,]	0.008770577	0.006731719	3.46256503	0.62905943
[7,]	0.081255111	0.077526085	4.83090244	0.56567709
[8,]	0.092455939	0.110429603	6.61171224	0.47039507
[9,]	0.111097646	0.104332965	9.19650351	0.32599145
[10,]	-0.126777439	-0.136838596	12.58010713	0.18254432

[11,] -0.134488410 -0.144595403 16.40797596 0.08853409  
[12,] -0.052387383 -0.056086825 16.99188433 0.10811588  
[13,] -0.069596284 -0.036972429 18.02793174 0.11484505  
[14,] 0.083152884 0.066628227 19.51486277 0.10798480  
[15,] 0.171800364 0.146304834 25.89640376 0.26682851  
[16,] 0.033131147 0.046890194 26.13502234 0.36627191  
[17,] 0.007650801 0.022474563 26.14781650 0.05198352  
[18,] -0.105809004 -0.069143130 28.60831438 0.03831310  
[19,] 0.061182790 0.110032691 29.43554978 0.04330906  
[20,] -0.017094562 -0.032553278 29.50048683 0.05850964  
[21,] 0.027005508 -0.019923252 29.66345426 0.07549353  
[22,] 0.138640773 0.034587125 33.98273146 0.03639382  
[23,] 0.071582250 0.065009134 35.14067279 0.03745353  
[24,] -0.090111482 -0.042618583 36.98609920 0.03262263  
[25,] -0.096709166 -0.072236529 39.12379726 0.02650325  
[26,] -0.057590082 -0.024666765 39.88621900 0.02995877  
[27,] -0.070046700 -0.071967609 41.02065082 0.03088597  
[28,] 0.054661531 0.033560623 41.71548995 0.03510313  
[29,] 0.162327751 0.142430957 47.87914839 0.01104168  
[30,] -0.064550223 -0.086494084 48.85953123 0.01194956  
[31,] -0.059395196 -0.054716134 49.69449007 0.01333967  
[32,] -0.048168756 0.004796315 50.24691175 0.01582786  
[33,] -0.085595658 -0.033914398 52.00174613 0.01416391  
[34,] -0.033479327 -0.052207580 52.27182742 0.01777597  
[35,] -0.013991818 -0.092649980 52.31928586 0.02316966  
[36,] 0.047557816 -0.027877236 52.87091739 0.02681882  
[37,] -0.027504038 -0.094920880 53.05655008 0.03325049



Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ ) pada lag k 18, 19 dan lag  $k \geq 22$

### Model 8 ARIMA (2,1,0)




```
> hasil_8=acfStat(dugaan8$residuals)
```

```
> hasil_8
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

### Model 9 ARIMA (2,1,1)




```
> hasil_9=acfStat(dugaan6$residuals)
```

```
> hasil_9
```

Berdasarkan perintah diatas , p-value tidak signifikan ( $< 0,05$ )

Model 10 ARIMA (2,1,2)



```
> hasil_10=acfStat(dugaan10$residuals)
```

```
> hasil_10
```

	ACF	PACF	Q-Stats	P-Value
[1,]	1.0000000000	1.000000e+00	NA	NA
[2,]	-0.018392946	-1.839295e-02	0.06834182	0.79376656
[3,]	-0.005272905	-5.613105e-03	0.07398707	0.96368237
[4,]	0.124063439	1.239085e-01	3.21507932	0.35963797
[5,]	-0.120488551	-1.178712e-01	6.19295174	0.18519447
[6,]	-0.030644416	-3.306643e-02	6.38657168	0.27039942
[7,]	0.038351465	2.253098e-02	6.69140030	0.35033125
[8,]	0.070297332	1.030303e-01	7.72089851	0.35784697
[9,]	0.140205144	1.408408e-01	11.83754583	0.15860070
[10,]	-0.049221974	-6.456798e-02	12.34759682	0.19441512
[11,]	-0.021765981	-4.331855e-02	12.44786055	0.25620001


[12,] 0.064942164 5.509692e-02 13.34517528 0.27136477  
 [13,] 0.005992152 6.714324e-02 13.35285550 0.34392373  
 [14,] 0.125305826 1.361177e-01 16.72944850 0.21196914  
 [15,] 0.190965878 1.641963e-01 24.61421711 0.13857251  
 [16,] 0.048688823 4.149158e-02 25.12955236 0.14823038  
 [17,] 0.019452936 -7.847807e-03 25.21226433 0.06616978  
 [18,] -0.086309125 -9.165437e-02 26.84942451 0.06031338  
 [19,] 0.072318991 1.168511e-01 28.00520477 0.06197604  
 [20,] -0.019728551 -8.679310e-03 28.09169499 0.08167976  
 [21,] 0.002114565 -1.979829e-03 28.09269416 0.10722320  
 [22,] 0.122454718 2.050899e-02 31.46230833 0.06630065  
 [23,] 0.059352285 3.812284e-02 32.25837741 0.07309644  
 [24,] -0.092347600 -8.314307e-02 34.19652878 0.06236938  
 [25,] -0.076774432 -1.103814e-01 35.54376675 0.06073496  
 [26,] -0.036482462 -6.125151e-02 35.84972923 0.07391110  
 [27,] -0.076553453 -1.133419e-01 37.20470832 0.07163805  
 [28,] 0.044572799 -9.185298e-05 37.66672802 0.08327962  
 [29,] 0.158220577 1.131735e-01 43.52242980 0.30961841  
 [30,] -0.061476533 -1.115436e-01 44.41166970 0.33531652  
 [31,] -0.039926427 -8.112692e-02 44.78896668 0.40382100  
 [32,] -0.018188371 -1.909929e-02 44.86773062 0.05121697  
 [33,] -0.072574412 -2.500760e-02 46.12926682 0.05066103  
 [34,] -0.036037970 -3.102497e-02 46.44220726 0.06039539  
 [35,] -0.024462126 -6.596595e-02 46.58726923 0.07363126  
 [36,] 0.035123518 -3.732749e-03 46.88815477 0.08633735  
 [37,] -0.027629833 -7.271134e-02 47.07548939 0.10238333

Berdasarkan perintah diatas , semua nilai p-value signifikan ( $>0,05$ )

Model 11 ARIMA (2,1,3)

```
> hasil_11=acfStat(dugaan11$residuals)
```

```
> hasil_11
```



Berdasarkan perintah diatas , nilai p-value tidak signifikan ( $>0,05$ ) pada lag  $k \geq 18$

#### 4. Peramalan

```
> Prediksi=forecast(dugaan10,h=12)
```

```
> plot(Prediksi)
```

